



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y
Tecnología

Máster Universitario en Inteligencia Artificial

Estudio comparativo de mo-
delos de aprendizaje profun-
do para el tratamiento de
documentación logística in-
dustrial

Trabajo Fin de Estudios

presentado por: Daniel Hidalgo Ocaña

Dirigido por: María Flores Ceballos

Ciudad: Barcelona

Fecha: 22 de julio de 2026

Índice de Contenidos

Glosario de Acrónimos y Siglas	VI
Resumen	IX
Abstract	X
1 Introducción	1
1.1 Motivación	3
1.2 Planteamiento del trabajo	4
1.3 Estructura de la memoria	6
2 Contexto y estado del arte	7
2.1 Contexto	7
2.2 Estado del Arte	9
2.2.1 Modelos basados en OCR y técnicas de PLN	12
2.2.2 Modelos basados en Layout y enfoques multimodales con lectura externa	16
2.2.3 Modelos generativos de traducción directa de imagen a texto (OCR- Free)	20
2.2.4 Paradigmas de IA Documental y el dilema del despliegue en entornos industriales	22
2.3 Conclusiones del estado del arte	24
3 Objetivos y Metodología de Trabajo	27
3.1 Objetivo general	27
3.2 Objetivos específicos	28
3.3 Metodología de trabajo	29
4 Desarrollo de la Comparativa	31

4.1	Bases de datos y análisis preliminar	31
4.1.1	Evaluación en dominio público: Dataset CORD	31
4.1.2	Generación del Dataset Sintético Logístico Industrial	33
4.1.3	Simulación de condiciones operativas	36
4.2	Selección de modelos para la comparativa	37
4.2.1	<i>PaddleOCR</i>	38
4.2.2	<i>LayoutLMv3</i>	38
4.2.3	<i>DONUT</i>	39
4.3	Entorno de experimentación	40
4.3.1	Infraestructura de cómputo y aceleración gráfica	40
4.3.2	Ecosistema de software y dependencias base	41
4.3.3	Controles de reproducibilidad y aislamiento	42
4.4	Diseño experimental y estrategia de optimización	42
4.4.1	Fase 1: Evaluación inicial sobre CORD	43
4.4.2	Fase 2: Adaptación al dominio y validación en entorno operativo . .	43
4.5	Protocolo y métricas de evaluación	48
4.5.1	Correspondencia entre predicciones y referencias	48
4.5.2	Métricas de eficacia de extracción	49
4.5.3	Estrategias de agregación estadística de métricas	52
4.5.4	Métricas de eficiencia computacional	52
5	Resultados y Análisis Comparativo	54
5.1	Evaluación base sobre el dataset CORD	55
5.1.1	Resultados de cuantitativos de la extracción de información clave . .	55
5.1.2	Análisis de Eficiencia Computacional	56
5.2	Evaluación sobre el dominio logístico-industrial español	57
5.2.1	Modelo <i>LayoutLMv3</i>	57
5.2.2	Modelo <i>DONUT</i>	62
5.3	Análisis Comparativo Global	68
5.3.1	Análisis comparativo de la extracción de información clave	69
5.3.2	Impacto de la Degradación Visual	72
5.3.3	Eficiencia Computacional	75
5.4	Síntesis de Resultados	77

6 Conclusiones y Trabajos Futuros	79
6.1 Conclusiones del Estudio	79
6.2 Cumplimiento de Objetivos	80
6.3 Trabajos Futuros	81
Referencias	82
A Resumen de verdaderos positivos, falsos positivos y falsos negativos	87
A.1 <i>LayoutLMv3</i>	88
A.2 DONUT	89
B Repositorio del Proyecto	90

Índice de Ilustraciones

Figura 1. Evolución prevista del mercado logístico global en el periodo 2025–2034	1
Figura 2. Arquitectura del detector de texto DB	12
Figura 3. Estructura de CRAFT	13
Figura 4. Arquitectura del marco PP-OCR	14
Figura 5. Ejemplo visual de la tarea de NER	15
Figura 6. Arquitectura del modelo LayoutLM	17
Figura 7. Estructura y objetivos de preentrenamiento de <i>LayoutLMv3</i>	18
Figura 8. Arquitectura general del modelo mmLayout	19
Figura 9. Arquitectura general del modelo DONUT	20
Figura 10. Ejemplo de documento del dataset CORD	32
Figura 11. Ejemplo de albarán logístico generado por el motor sintético	35
Figura 12. Ejemplos de albaranes sintéticos tras la aplicación del aumento de datos	37
Figura 13. Precisión y <i>Recall</i> de <i>LayoutLMv3</i>	60
Figura 14. Precisión y <i>Recall</i> de <i>DONUT</i>	66
Figura 15. <i>F1-Score</i> por entidad en el escenario base	71
Figura 16. Evolución del rendimiento global con ruido	73
Figura 17. Impacto de la degradación visual en <i>LayoutLMv3</i> y <i>DONUT</i>	74
Figura 18. Coste computacional durante el entrenamiento	76
Figura 19. Resultados detallados de <i>LayoutLMv3</i>	88
Figura 20. Resultados detallados de <i>DONUT</i>	89

Índice de Tablas

Tabla 1.	Paradigmas arquitectónicos en IA documental	23
Tabla 2.	Modelos y paradigmas de extracción	31
Tabla 3.	Configuración de hiperparámetros	48
Tabla 4.	Extracción del campo <code>total_price</code> en CORD	55
Tabla 5.	Costes computacionales de inferencia sobre la muestra de 95 recibos.	57
Tabla 6.	Resultados de extracción con <i>LayoutLMv3</i>	58
Tabla 7.	Métricas globales de <i>LayoutLMv3</i>	60
Tabla 8.	Coste computacional de <i>LayoutLMv3</i>	61
Tabla 9.	Extracción de información clave con DONUT	64
Tabla 10.	Métricas globales de <i>DONUT</i>	65
Tabla 11.	Coste computacional de <i>DONUT</i>	67
Tabla 12.	Comparativa del <i>F1-Score</i> global	69
Tabla 13.	Requerimientos operativos en inferencia	75

Glosario de Acrónimos y Siglas

2PL	Second-Party Logistics
3PL	Third-Party Logistics
4PL	Fourth-Party Logistics
AMP	Automatic Mixed Precision (Precisión Mixta Automática)
ANLS	Average Normalized Levenshtein Similarity (Similitud de Levenshtein Normalizada)
BART	Bidirectional and Auto-Regressive Transformers
BIO	Begin, Inside, Outside (Esquema de etiquetado para NER)
BPM	Business Process Management (Gestión de Procesos de Negocio)
CAGR	Compound Annual Growth Rate (Tasa de Crecimiento Anual Compuesto)
CER	Character Error Rate (Tasa de Error de Caracteres)
CIF	Código de Identificación Fiscal
CORD	Consolidated Receipt Dataset for Post-OCR Parsing
CPU	Central Processing Unit (Unidad Central de Procesamiento)
CRF	Conditional Random Fields (Campos Aleatorios Condicionales)
CUDA	Compute Unified Device Architecture (Plataforma de Computación Paralela de NVIDIA)
DocVQA	Document Visual Question Answering
DONUT	Document Understanding Transformer
ERP	Enterprise Resource Planning (Sistema de Planificación de Recursos Empresariales)
FN	Falso Negativo

FP	Falso Positivo
FP16	16-bit Floating Point (Punto Flotante de 16 Bits)
FP32	32-bit Floating Point (Punto Flotante de 32 Bits)
GB	Gigabyte
GPU	Graphics Processing Unit (Unidad de Procesamiento Gráfico)
GT	Ground Truth (Verdad de Referencia)
IA	Inteligencia Artificial
IoT	Internet of Things (Internet de las Cosas)
JSON	JavaScript Object Notation (Formato Ligero de Intercambio de Datos)
KIE	Key Information Extraction (Extracción de Información Clave)
LLM	Large Language Model (Modelo de Lenguaje de Gran Escala)
LR	Learning Rate (Tasa de Aprendizaje)
LSTM	Long Short-Term Memory (Memoria a Largo-Corto Plazo)
ML	Machine Learning (Aprendizaje Automático)
NER	Named Entity Recognition (Reconocimiento de Entidades Nombradas)
OCR	Optical Character Recognition (Reconocimiento Óptico de Caracteres)
OOM	Out Of Memory (Error por Falta de Memoria)
PL	Party Logistics
PLN	Procesamiento del Lenguaje Natural
RAM	Random Access Memory (Memoria de Acceso Aleatorio)
RegEx	Regular Expression (Expresión Regular)
RGPD	Reglamento General de Protección de Datos
RNN	Recurrent Neural Network (Red Neuronal Recurrente)

ROI	Region of Interest (Región de Interés)
Seq2Seq	Sequence-to-Sequence (Secuencia a Secuencia)
ST-VQA	Scene Text Visual Question Answering
SVM	Support Vector Machine (Máquina de Vectores de Soporte)
USD	United States Dollar (Dólar Estadounidense)
VLM	Vision-Language Model (Modelo Visión-Lenguaje)
VP	Verdadero Positivo
VQA	Visual Question Answering (Respuesta a Preguntas sobre Imágenes)
VRAM	Video Random Access Memory (Memoria Gráfica)
VRD	Visually Rich Documents (Documentos Visualmente Ricos)
WD	Weight Decay (Decaimiento de Pesos)

Resumen

El sector de la logística industrial genera diariamente un gran volumen de albaranes y documentos mercantiles cuya digitalización y procesamiento manual suponen un importante cuello de botella operativo y económico. La automatización de este flujo presenta desafíos relevantes como la confidencialidad de los datos, la elevada diversidad de formatos y el deterioro físico de los documentos en los entornos de trabajo constituyen factores que limitan significativamente la eficacia de los sistemas tradicionales basados en reglas.

Para abordar estos retos, el presente trabajo propone un estudio empírico y comparativo de técnicas avanzadas de Inteligencia Artificial Documental orientadas a la extracción de información clave. Los algoritmos seleccionados representan el estado del arte actual y pueden desplegarse en entornos locales, garantizando la soberanía del dato.

Desde el punto de vista metodológico, se utiliza inicialmente un conjunto de datos público para evaluar los modelos preentrenados y establecer una línea base de referencia. Posteriormente, se lleva a cabo un proceso de ajuste fino sobre un conjunto de datos sintético desarrollado específicamente para este trabajo, con el objetivo de adaptar los modelos al dominio logístico. Una vez completada esta adaptación, se introduce ruido visual controlado para analizar su impacto sobre el rendimiento de los distintos enfoques.

Los resultados muestran que, bajo condiciones visuales favorables, arquitecturas multimodales como *LayoutLMv3* alcanzan una elevada capacidad de extracción. Sin embargo, su rendimiento se reduce de forma notable ante altos niveles de degradación visual, debido a la propagación de errores procedentes del sistema de reconocimiento óptico de caracteres del que dependen. Por el contrario, el modelo generativo *DONUT* presenta una mayor robustez en escenarios visualmente adversos y adopta una estrategia de predicción más conservadora, orientada a minimizar las extracciones incorrectas.

En términos de eficiencia operativa, *DONUT* reduce significativamente los costes, tiempos de entrenamiento y mantiene una latencia de inferencia más estable frente a documentos degradados. En conjunto, los resultados indican que este paradigma generativo constituye la alternativa más adecuada para su despliegue en entornos productivos, al ofrecer el mejor equilibrio entre rendimiento, eficiencia y fiabilidad operativa.

Palabras clave: Inteligencia Artificial Documental, Extracción de Información Clave, Logística Industrial.

Abstract

The industrial logistics sector generates a large volume of delivery notes and commercial documents on a daily basis, whose digitization and manual processing represent a significant operational and economic bottleneck. Automating this workflow poses important challenges, such as data confidentiality, the high diversity of document formats, and the physical deterioration of documents in working environments, all of which significantly limit the effectiveness of traditional rule-based systems.

To address these challenges, this work presents an empirical and comparative study of advanced Document Artificial Intelligence techniques for key information extraction. The selected algorithms represent the current state of the art and can be deployed in on-premises environments, thereby ensuring data sovereignty.

From a methodological perspective, a public dataset is first used to evaluate pre-trained models and establish a baseline. Subsequently, a fine-tuning process is carried out on a synthetic dataset specifically developed for this work in order to adapt the models to the logistics domain. Once this adaptation is completed, controlled visual noise is introduced to analyze its impact on the performance of the different approaches.

The results show that, under favorable visual conditions, multimodal architectures such as *LayoutLMv3* achieve high information extraction performance. However, their effectiveness decreases considerably under severe visual degradation due to the propagation of errors from the Optical Character Recognition system on which they depend. In contrast, the generative model *DONUT* demonstrates greater robustness in visually adverse scenarios and adopts a more conservative prediction strategy aimed at minimizing incorrect extractions.

In terms of operational efficiency, *DONUT* significantly reduces training costs and time while maintaining a more stable inference latency when processing degraded documents. Overall, the results indicate that this generative paradigm constitutes the most suitable alternative for deployment in production environments, offering the best balance between performance, efficiency, and operational reliability.

Keywords: Document Artificial Intelligence, Key Information Extraction, Industrial Logistics.

1. Introducción

En la actualidad, la progresiva interconexión global y los cambios en la organización de los procesos productivos ha situado la cadena de suministro como una pieza clave para el funcionamiento de la economía a nivel internacional (Zhu, 2023).

Según consultoras globales como IMARC Group el tamaño del mercado logístico mundial fue valorado en 2025 en 5,9 billones de dólares y se estima que alcance los 8,2 billones para 2034 (IMARC Group, 2025). Como se muestra en la figura 1, **esta evolución refleja una tendencia de crecimiento sostenido del sector logístico a medio y largo plazo, registrando una tasa de crecimiento anual compuesta (CAGR, del inglés *Compound Annual Growth Rate*) estimada del 3,71 % para el periodo 2026–2034.**




Figura 1: Evolución prevista del mercado logístico global en el periodo 2025–2034, expresado en billones de dólares (USD). Desglosado por modelo de servicio: 3PL (Third-Party Logistics), 2PL (Second-Party Logistics) y 4PL (Fourth-Party Logistics). El gráfico muestra un crecimiento progresivo anual, pasando de aproximadamente 5.9 billones USD en 2025 hasta 8.2 billones USD en 2034. Se observa que el segmento 3PL representa la mayor proporción en todos los años, seguido por 2PL y 4PL. La tasa de crecimiento anual compuesta (CAGR) estimada para el periodo 2026–2034 es del 3.71 %.

Este mercado global se analiza habitualmente desglosado según el nivel de externalización de los servicios, conocidos como modelos *Party Logistics* (PL). En particular, se distinguen los proveedores 2PL (*Second-Party Logistics*), encargados puramente del transporte físico; los 3PL (*Third-Party Logistics*), que asumen de forma integrada tanto el

almacenamiento como la gestión operativa y los 4PL (*Fourth-Party Logistics*), que actúan como optimizadores y gestores estratégicos de toda la cadena de suministro. Como se aprecia en las estimaciones, el segmento 3PL continuará potencialmente representando la mayor proporción del mercado.

Este crecimiento se atribuye al aumento de las compras en línea, a la creciente demanda de servicios de mensajería más rápidos, a los avances en tecnologías como el internet de las cosas (IoT, del inglés *Internet of Things*) y la Inteligencia Artificial (IA), a un mayor impulso del transporte ecológico y a las mejoras en la infraestructura logística.

En particular, los modelos basados en IA y aprendizaje automático (ML, del inglés *Machine Learning*) son capaces de transformar los procesos involucrados en la logística industrial, haciéndolos más eficientes, rápidos y precisos. **De acuerdo con estudios realizados por McKinsey (2021), la IA ha permitido mejorar los costes logísticos en un 15 %, reducir los niveles de inventario en un 35 % y aumentar los niveles de servicio en un 65 %.** (McKinsey & Company, 2021), cifras que muestran las ganancias potenciales derivadas de estas tecnologías.

La IA ha encontrado numerosas aplicaciones en el ámbito de la logística industrial, como el análisis predictivo para mejorar las previsiones de demanda, la optimización de rutas o la gestión automatizada de inventarios (Frikha y Mrad, 2025). Más allá de estas aplicaciones, la automatización del tratamiento documental constituye un área de creciente interés debido al elevado volumen de información que generan los procesos logísticos. En este contexto, **resulta fundamental evaluar la capacidad de distintos modelos de IA para realizar tareas de extracción de información clave (KIE, del inglés *Key Information Extraction*) y estructurar de forma fiable los datos contenidos en documentos logísticos.**

Con este objetivo, en el presente trabajo se realiza un análisis comparativo de distintas tecnologías de IA aplicadas al procesamiento automático de documentos en entornos logístico-industriales. El objetivo es comparar su capacidad para extraer y estructurar información relevante de forma fiable en condiciones reales. Para ello, se estudian modelos representativos de diferentes enfoques, desde soluciones tradicionales basadas en Reconocimiento Óptico de Caracteres (OCR, del inglés *Optical Character Recognition*) hasta arquitecturas más avanzadas de tipo multimodal, considerando tanto su rendimiento como sus requisitos de despliegue en entornos locales, tales como el tiempo de inferencia y las demandas computacionales.

1.1. Motivación

La motivación de este trabajo nace de la necesidad de dar respuesta a una problemática presente en numerosos entornos de logística industrial, donde **la gestión manual o semiautomatizada de documentos continúa actuando como cuello de botella en procesos clave como la recepción de mercancías, la gestión de almacenes o el control de inventarios.**

En una gran cantidad de entornos logísticos, la gestión documental sigue dependiendo de documentos físicos, como albaranes, órdenes de expedición, etiquetas logísticas o registros de entrada y salida de material, que son escaneados o fotografiados mediante dispositivos móviles, requiriendo posteriormente su digitalización e introducción manual en sistemas informáticos. Estos documentos presentan importantes limitaciones operativas, como condiciones de captura no controladas (iluminación deficiente, ruido digital), presencia de deterioro físico (arrugas, manchas o sellos superpuestos) y una elevada heterogeneidad en la estructura de tablas, códigos y formularios.

Como consecuencia, esta forma de trabajo ralentiza el acceso a la información y dificulta la homogeneización de los datos, lo que incrementa la probabilidad de errores manuales. Esta falta de digitalización impacta de manera directa en la trazabilidad de las mercancías, especialmente en operaciones críticas como la conciliación entre albaranes y órdenes de compra o el seguimiento del stock en tiempo real. En definitiva, la ausencia de un registro estructurado limita la visibilidad sobre los flujos logísticos y condiciona la capacidad de las organizaciones para tomar decisiones basadas en datos actualizados y fiables.

En este escenario, la automatización de la extracción de información cobra especial relevancia en la logística industrial, ya que permite unificar formatos documentales, consolidar datos procedentes de múltiples actores de la cadena de suministro (proveedores, transportistas, almacenes) y construir registros históricos coherentes y consistentes. Estas capacidades facilitan tanto el análisis posterior, por ejemplo, en la optimización de niveles de inventario o la detección de desviaciones, como la mejora continua de los procesos logísticos.

Adicionalmente, los entornos de logística industrial imponen requisitos específicos que condicionan la adopción de soluciones de IA. Entre estos, destaca la necesidad de garantizar la protección, privacidad y soberanía de los datos, especialmente cuando se gestionan datos sensibles relacionados con proveedores, contratos o movimientos de mercancía. Fren-

te a este escenario, la adopción de modelos de código abierto, entendidos como aquellos cuyo diseño, arquitectura y código fuente son accesibles públicamente y pueden ser utilizados, modificados y redistribuidos, permite el despliegue de soluciones en entornos locales. Este enfoque no solo facilita el cumplimiento del Reglamento General de Protección de Datos (RGPD), sino que además elimina la dependencia de terceros proveedores tecnológicos, evitando la necesidad de transferir información sensible a infraestructuras externas o servicios en la nube.

Ante la amplia diversidad de modelos y técnicas de IA orientadas al procesamiento automático de documentos, el presente Trabajo de Fin de Máster plantea un análisis comparativo de modelos de aprendizaje profundo de código abierto enfocados en la extracción, interpretación y comprensión de documentación logística. **Con esta propuesta, se busca paliar las ineficiencias previamente identificadas, teniendo como objetivos fundamentales la mejora de la eficiencia operativa, la trazabilidad y la fiabilidad de los datos en toda la cadena logística.**

1.2. Planteamiento del trabajo

El objetivo principal de este trabajo es realizar un estudio comparativo de distintas arquitecturas de IA documental aplicadas al tratamiento automático de documentación logística industrial, con especial atención a la extracción de información clave contenida en albaranes. Este planteamiento se fundamenta en la escasez de estudios comparativos en la literatura actual orientados a identificar qué arquitectura ofrece un mejor ajuste en función del escenario de aplicación. Como se expone en el capítulo 2, en la actualidad conviven enfoques muy diversos, desde motores OCR tradicionales hasta modelos multimodales y arquitecturas generativas *OCR-free*, cada uno de ellos con ventajas, limitaciones y requisitos computacionales distintos. **En este contexto, resulta pertinente establecer una comparación sistemática que permita valorar su aplicabilidad real en entornos logísticos industriales.**

La pregunta de investigación que guía este estudio es la siguiente:

¿Qué equilibrio ofrecen los principales modelos de IA documental de código abierto para la extracción de información clave en albaranes del ámbito logístico industrial en términos de precisión, robustez frente al ruido y a la variabilidad documental, y coste computacional?

Esta cuestión es especialmente relevante en el ámbito logístico, donde los documentos presentan una notable heterogeneidad en su estructura, calidad visual y condiciones de captura. **Frente a ello, los enfoques tradicionales basados en reglas o plantillas muestran importantes limitaciones de adaptación, mientras que las técnicas de aprendizaje profundo permiten modelar patrones complejos en el contenido, la disposición espacial y la apariencia visual de los documentos.**

Para dar respuesta a esta pregunta, el alcance del trabajo se define de la siguiente manera:

- **Modelos a comparar:** se seleccionará un conjunto representativo de seis modelos de código abierto pertenecientes a distintas familias tecnológicas del procesamiento documental, con objeto de evaluar comparativamente sus prestaciones en escenarios logísticos industriales.
- **Contexto de evaluación:** el análisis se realizará sobre documentación logística industrial, particularmente albaranes, caracterizada por una elevada variabilidad en diseño, maquetación y calidad de imagen. Este tipo de documentos constituye un caso de uso especialmente exigente, ya que combina ruido visual, estructuras semiestructuradas y dependencia del contexto espacial para interpretar correctamente los campos relevantes.
- **Criterios de comparación:** la evaluación empírica se orientará tanto al rendimiento documental como a la viabilidad de despliegue. Para ello, se emplearán métricas ampliamente utilizadas en la literatura, como la tasa de error de caracteres (CER, del inglés *Character Error Rate*), la similitud de Levenshtein normalizada (ANLS, del inglés *Average Normalized Levenshtein Similarity*) y el *F1-Score* por entidad, complementadas con medidas de tiempo de inferencia y robustez frente al ruido. De este modo, no solo se valorará la exactitud de extracción, sino también el equilibrio entre capacidad de comprensión documental y coste computacional.
- **Finalidad práctica del estudio:** a partir de esta comparación se pretende identificar qué tipo de arquitectura resulta más adecuada para escenarios logísticos reales, determinando si el posible incremento de precisión de los modelos más complejos justifica las mayores exigencias de infraestructura y procesamiento que su adopción conlleva.

1.3. Estructura de la memoria

Con el fin de alcanzar los objetivos definidos y presentar los resultados, la memoria se organiza en varios capítulos, cuya estructura se describe a continuación.

- **El primer capítulo** introduce el marco general del trabajo, situando el estudio en el contexto logístico actual. En él, se expone la motivación que impulsa la investigación, se justifica la relevancia tecnológica del problema abordado y se presenta de forma sintética el planteamiento general y las principales aportaciones del trabajo.
- **El segundo capítulo** aborda el contexto teórico y el estado del arte, realizando una revisión de la literatura científica reciente relacionada con la IA documental. Asimismo, se analiza la evolución de las técnicas empleadas, desde los sistemas tradicionales basados en OCR hasta los enfoques más avanzados, incluidos los modelos multimodales y las arquitecturas *OCR-free* aplicadas a documentos industriales.
- **El tercer capítulo** define de manera precisa los objetivos generales y específicos del estudio, así como la metodología empleada, el conjunto de datos utilizado para la evaluación y las métricas consideradas para el análisis del rendimiento de los modelos.
- **El cuarto capítulo** detalla el diseño y planteamiento de la comparativa experimental. En esta sección se definen los conjuntos de datos empleados y las arquitecturas neuronales seleccionadas. Asimismo, se establecen las métricas de evaluación para medir la precisión y la robustez frente al ruido, precisando las estrategias de optimización computacional aplicadas para viabilizar el entrenamiento y despliegue.
- **El quinto capítulo** presenta los resultados obtenidos durante la experimentación y su correspondiente análisis comparativo. En particular, se evalúa el comportamiento de las distintas arquitecturas en términos de precisión de extracción, robustez frente a la degradación visual y eficiencia computacional. Asimismo, se estudia su capacidad de adaptación al dominio logístico industrial y se discuten las principales ventajas y limitaciones observadas en cada enfoque.
- **El sexto capítulo** recoge las conclusiones principales derivadas del estudio, relacionándolas con los objetivos y requisitos inicialmente planteados. Asimismo, se proponen posibles líneas de trabajo futuro orientadas a la mejora y ampliación de las soluciones analizadas para su aplicación en contextos logísticos reales.

2. Contexto y estado del arte

Este capítulo proporciona el marco conceptual necesario para comprender la evolución de las tecnologías empleadas en la extracción automática de información a partir de documentos utilizados en entornos industriales.

A continuación, se presenta una revisión técnica que abarca desde los sistemas clásicos de reconocimiento óptico de caracteres hasta las arquitecturas multimodales más recientes, que integran información visual, textual y espacial. El propósito de este análisis es contextualizar el estado actual de la IA Documental, poniendo el foco en cómo el avance en técnicas de aprendizaje profundo ha permitido superar las limitaciones inherentes a los enfoques basados en reglas.

2.1. Contexto

Para comprender el alcance de este trabajo, resulta necesario definir la naturaleza del problema operativo dentro del entorno de la cadena de suministro industrial.

El ámbito logístico, especialmente en plantas de alta cadencia de producción, es una pieza clave para la continuidad de las operaciones. En este contexto, donde se trabaja bajo un modelo de suministro sincronizado con la demanda y con niveles mínimos de inventario, cualquier retraso o error en el flujo de información puede tener un impacto inmediato en la producción. **Tanto la recepción como la expedición de materiales y componentes se gestionan a través de documentos físicos o parcialmente estructurados, que constituyen la base para validar la entrada de mercancías, mantener el control del inventario y asegurar la trazabilidad de los elementos.**

En este sentido, los albaranes de entrega se emplean como un caso representativo especialmente relevante, ya que reflejan de forma clara la complejidad inherente a este tipo de documentación. Estos documentos comerciales, utilizados para certificar la recepción de mercancías, presentan una serie de características que los convierten en un escenario exigente para los sistemas de procesamiento automático:

1. **Alta heterogeneidad en el formato:** Cada proveedor define su propio diseño documental, lo que provoca que la información relevante (como número de pieza, cantidad o identificador de lote) no se encuentre en posiciones estandarizadas. Asimismo, otros campos clave, como proveedor o fecha, pueden aparecer en distintas

zonas del documento, como encabezados o pies, sin consistencia entre formatos.

2. **Degradación y ruido en los documentos:** Debido a su uso en entornos industriales, los documentos suelen presentar daños físicos o baja calidad visual. Es frecuente encontrar arrugas, manchas, pliegues, impresiones deficientes o digitalizaciones realizadas mediante dispositivos móviles en condiciones de iluminación no controladas.
3. **Extracción de información clave:** A diferencia de los sistemas tradicionales de OCR, cuyo objetivo es la transcripción completa del documento, el enfoque actual se centra en identificar y estructurar información específica de valor. Esto implica transformar contenido no estructurado en entidades semánticas definidas. La precisión es crítica, ya que errores en identificadores o cantidades pueden generar incidencias operativas relevantes.

La IA Documental consiste en la aplicación de tecnologías avanzadas, como la visión computacional y el procesamiento de lenguaje natural (PLN), para automatizar la extracción, interpretación y estructuración de la información contenida en documentos no estructurados o semiestructurados.

La implementación de soluciones de IA Documental en entornos industriales plantea retos técnicos y organizativos que van más allá del rendimiento de los modelos. Desde el punto de vista operativo, los sistemas deben mantener un comportamiento robusto en condiciones adversas, incluyendo ruido visual, variabilidad en el layout, documentos deteriorados y digitalización en entornos no controlados.

A estos desafíos se añaden consideraciones clave relacionadas con la gestión de los datos. En el ámbito industrial, los documentos procesados contienen frecuentemente información sensible asociada a procesos productivos, relaciones comerciales o propiedad intelectual. En este contexto, la soberanía del dato y el cumplimiento de la normativa en materia de protección de la información se convierten en factores determinantes en la selección de soluciones tecnológicas. En este sentido, la literatura (Ogrezeanu y cols., 2022) advierte sobre los riesgos de privacidad y seguridad asociados a la externalización de datos corporativos hacia servicios de terceros en la nube. Para garantizar la soberanía de la información y mantener el control estricto sobre su ciclo de vida, este estudio recomienda el despliegue de sistemas en infraestructuras locales.

Es precisamente para dar respuesta a esta exigencia de privacidad por lo que, en el presente trabajo, se recurre a modelos de código abierto, ya que son los únicos que

viabilizan este tipo de despliegues aislados sin depender de APIs (del inglés *Application Programming Interface*) comerciales externas.

Por consiguiente, satisfacer los requisitos de confidencialidad y operatividad propios del sector logístico industrial no solo exige el uso de infraestructuras locales, sino también la selección de modelos capaces de interpretar de forma robusta tanto el contenido semántico como la estructura espacial de los albaranes. **Con el fin de fundamentar técnicamente dicha selección, resulta necesario analizar la evolución de las tecnologías de procesamiento documental y comprender cómo la investigación ha transitado desde los sistemas tradicionales de reconocimiento de caracteres hasta los actuales enfoques multimodales y generativos.** Para ello, la siguiente sección presenta una revisión del estado del arte orientada a identificar las fortalezas y limitaciones de los principales paradigmas de IA documental frente al escenario logístico industrial considerado en este trabajo.

2.2. Estado del Arte

En (Memon, Sami, Khan, y Uddin, 2020) se presenta una revisión reciente de la evolución histórica de los sistemas de Reconocimiento Óptico de Caracteres (OCR) hasta el año 2020. En este estudio, los autores destacan que la primera revolución en la automatización del flujo de datos administrativos llegó con el desarrollo del OCR clásico, el cual permitió la conversión de imágenes bidimensionales de texto en cadenas de caracteres codificados digitalmente mediante algoritmos de binarización, segmentación de líneas y emparejamiento de matrices de fuentes fijas o análisis de características estadísticas.

Asimismo, destacan cómo los primeros motores de OCR de código abierto que alcanzaron madurez industrial, como el ampliamente adoptado proyecto Tesseract OCR (Smith, 2007; Tesseract OCR Project, 2021), evolucionaron desde enfoques basados en análisis heurísticos y reconocimiento topológico de caracteres hasta arquitecturas fundamentadas en redes neuronales recurrentes (RNN, del inglés *Recurrent Neural Network*) (Elman, 1990), particularmente aquellas basadas en mecanismos de memoria a largo-corto plazo (LSTM, del inglés *Long Short-Term Memory*) (Hochreiter y Schmidhuber, 1997b) para el modelado probabilístico de secuencias de texto.

Paralelamente, marcos de trabajo industriales como *PaddleOCR* (Du y cols., 2020; PaddleOCR, 2026) introdujeron arquitecturas de pipelines optimizadas capaces de ejecu-

tar tareas de detección de texto mediante redes convolucionales ligeras y reconocimiento secuencial en fracciones de segundo. Bajo este paradigma inicial, la extracción de información en entornos industriales se articuló mediante el desarrollo de sistemas rígidos basados en plantillas fijas. Estos sistemas requerían que un ingeniero de software definiera coordenadas cartesianas absolutas en el plano tridimensional virtual del documento para aislar regiones de interés específicas (ROI, del inglés *Regions of Interest*), asumiendo que los campos clave como el número de albarán o la descripción de la mercancía permanecerían siempre en posiciones geométricas inmutables.

La transición hacia la industria moderna ha demostrado la inviabilidad operativa de los sistemas basados en plantillas rígidas en el entorno de la logística industrial. Los albaranes se caracterizan por una heterogeneidad estructural intrínseca. Cada proveedor, operador logístico o agencia de aduanas diseña sus plantillas atendiendo a lógicas estéticas y funcionales arbitrarias. Un sistema basado en reglas no funciona ante variaciones mínimas en los márgenes de impresión, cambios en el tamaño o tipo de fuente, o la aparición de tablas multipágina con espaciados variables, exigiendo un esfuerzo de mantenimiento técnico inmanejable.

A este desafío de diseño se añade la variabilidad del entorno físico de captura. En los muelles de carga reales, la documentación se ve sometida a deterioros mecánicos severos, incluyendo pliegues, roturas, manchas y el desvanecimiento de tintas en impresoras térmicas de baja calidad. Además, los flujos modernos exigen que la digitalización se realice en movilidad mediante terminales de radiofrecuencia o teléfonos inteligentes. Esto introduce ruidos ópticos complejos como desenfoque por movimiento, distorsiones de perspectiva, sombras densas y condiciones de iluminación variables que distorsionan gravemente los caracteres individuales.

La urgencia por superar estos límites ha impulsado la integración del aprendizaje profundo en las operaciones logísticas. En estudios recientes sobre la adopción de tecnologías inteligentes en la gestión de la cadena de suministro (Frikha y Mrad, 2025), se demuestra que la aplicación de modelos avanzados de IA representa un salto cualitativo frente a las arquitecturas tradicionales. Los autores concluyen que la IA no se limita a optimizar flujos de trabajo algorítmicos puntuales como la previsión de la demanda o la sostenibilidad operativa, sino que eleva de forma holística la eficiencia de la cadena al dotar a los ecosistemas logísticos de capacidades de aprendizaje continuo y adaptación autónoma ante la variabilidad e incertidumbre del entorno físico.

Esta transformación operativa tiene un impacto directo en la agilidad organizacional. En (Verma, 2025) se analiza detalladamente el impacto de la IA en la gestión de procesos de negocio (BPM, del inglés *Business Process Management*), destacando cómo las organizaciones están superando las limitaciones de los sistemas de gestión rígidos para adentrarse en modelos de automatización cognitiva e hiperautomatización. Según expone este estudio, la verdadera reingeniería de los procesos exige abandonar la mera digitalización estática para integrar sistemas capaces de interpretar información de forma inteligente. **En el ámbito logístico-administrativo, esto implica migrar desde el simple reconocimiento de texto plano hacia el paradigma de la IA Documental, cuyo objetivo central es la comprensión semántica profunda de documentos visualmente ricos (VRD, del inglés *Visually Rich Documents*), transformando imágenes no estructuradas en esquemas de datos relacionales directamente operativos para los sistemas de planificación de recursos empresariales (ERP, del inglés *Enterprise Resource Planning*).**

Previo a la consolidación del aprendizaje profundo, la extracción de información en el ámbito documental se abordó mediante modelos de ML clásico, empleando algoritmos estadísticos como Máquinas de Vectores de Soporte (SVM, del inglés *Support Vector Machine*) (Cortes y Vapnik, 1995), Bosques Aleatorios (en inglés *Random Forest*) (Breiman, 2001) o Campos Aleatorios Condicionales (CRF, del inglés *Conditional Random Fields*) (Lafferty, McCallum, y Pereira, 2001). Sin embargo, según se expone en los estudios de (Xu y cols., 2020; Appalaraju, Jasani, Kota, Xie, y Manmatha, 2021), si bien estos enfoques resultaron útiles para tareas de clasificación sobre textos planos, presentaron limitaciones significativas al aplicarse a documentos visualmente ricos. En particular, **la dependencia de procesos de ingeniería manual de características (en inglés *feature engineering*) y las dificultades para modelar conjuntamente la información textual, espacial y visual de los documentos limitaron su capacidad de generalización, favoreciendo su progresiva sustitución por arquitecturas basadas en aprendizaje profundo.**

Por este motivo, la investigación contemporánea en el dominio de la IA Documental ha descartado los modelos tradicionales para orientarse en exclusiva al diseño de arquitecturas neuronales de aprendizaje profundo. Estas arquitecturas son capaces de procesar de forma nativa la naturaleza multimodal de los documentos semiestructurados, los cuales combinan texto legible, disposición espacial y características visuales.

El estado del arte de la literatura científica se divide actualmente en tres

grandes familias arquitectónicas, diferenciadas por su diseño y por el equilibrio que establecen entre precisión, robustez y coste computacional: los *pipelines* en cascada desestructurados (OCR + PLN), los modelos basados en *layout* y enfoques multimodales con lectura externa y los modelos generativos de traducción directa de imagen a texto (*OCR-Free*).

2.2.1. Modelos basados en OCR y técnicas de PLN

Este paradigma fragmenta el problema de la extracción de información en dos fases secuenciales y computacionalmente independientes. La primera fase aborda el problema de visión artificial mediante la detección y transcripción del texto contenido en el documento. El estado del arte en esta etapa emplea redes neuronales profundas para la detección de texto, muchas de ellas basadas en la segmentación de regiones textuales. Entre ellas destaca el algoritmo *Differentiable Binarization* (DBNet) (Liao, Zou, Wan, Yao, y Bai, 2023). Como se ilustra en la figura 2, DBNet incorpora un mecanismo de binarización diferenciable dentro de una red de pirámide de características (FPN, del inglés *Feature Pyramid Network*), permitiendo optimizar de forma adaptativa los umbrales de segmentación durante el entrenamiento. Este enfoque posibilita una delimitación más precisa de regiones textuales con morfologías complejas, al tiempo que mantiene velocidades de inferencia compatibles con aplicaciones en tiempo real (62 FPS (del inglés *Frames Per Second*)).




Figura 2: Arquitectura del detector de texto *Differentiable Binarization* (DB). Esta figura proviene del artículo de DB (Liao y cols., 2023). Los rectángulos rojos y grises muestran la red troncal (*backbone*) y la cabecera (*head*) del detector de texto por separado (Du y cols., 2020).

Otras aproximaciones notables emplean el algoritmo CRAFT (del inglés, *Character Region Awareness for Text Detection*) (Baek, Lee, Han, Yun, y Lee, 2019), que detecta el texto calculando de manera probabilística la afinidad entre caracteres individuales para construir regiones textuales sin depender de cajas rígidas. Una vez aisladas las regiones de texto, se aplican redes de reconocimiento de secuencias, típicamente estructuras CRNN (del inglés, *Convolutional Recurrent Neural Networks*) (Shi, Bai, y Yao, 2017), las cuales extraen mapas de características visuales mediante capas convolucionales, modelan las dependencias secuenciales de los caracteres a través de capas bidireccionales LSTM (Hochreiter y Schmidhuber, 1997a) y decodifican el texto final empleando una función de pérdida de Clasificación Temporal Conexionista (CTC, del inglés *Connectionist Temporal Classification*).




Figura 3: Estructura de CRAFT (Character Region Awareness for Text Detection). La arquitectura utiliza una red de extracción de características basada en VGG16-BN y una etapa de reconstrucción con bloques de aumento de resolución y combinación multiescala para predecir dos mapas de probabilidad: uno asociado a la región de los caracteres y otro a la afinidad entre caracteres, lo que permite una detección precisa de texto en escenas naturales (Baek y cols., 2019).

Modelos industriales altamente optimizados de código abierto, como *PaddleOCR* (Li y cols., 2022), estructuran este *pipeline* de manera eficiente. Este sistema incorpora módulos dedicados a la clasificación de la orientación espacial de las líneas de texto y algoritmos de reconocimiento avanzados basados en mecanismos de atención visual, como SVTR (del inglés, *Single Visual Model for Text Recognition*). **La integración de estos componentes consolida el marco unificado PP-OCR (Du y cols., 2020) como una referencia en ligereza y velocidad de ejecución en servidores locales.** Como se ilustra en el esquema de la figura 4, este sistema articula de manera secuencial la detección, rectificación y lectura del texto.




Figura 4: Arquitectura del marco PP-OCR propuesto. Los tamaños de modelo detallados en el diagrama corresponden al sistema de reconocimiento de caracteres chinos e ingleses. Para el reconocimiento específico de símbolos alfanuméricos, el tamaño del modelo de reconocimiento de texto se reduce de 1,6M a 0,9M, manteniendo el resto de los módulos el mismo tamaño (Du y cols., 2020).

Tras la transcripción visual, la segunda fase del pipeline introduce el texto extraído en un modelo de PLN. Para ello, la secuencia textual se descompone previamente en *tokens*, que son las unidades básicas de texto utilizadas por el modelo para procesar la información. Dependiendo del método de tokenización empleado, un *token* puede corresponder a una palabra completa, una parte de una palabra o incluso un carácter individual.

A continuación, el modelo de PLN aborda la tarea de Reconocimiento de Entidades Nombradas (NER, del inglés *Named Entity Recognition*). Como se muestra en la figura 5,

esta técnica consiste en identificar y asignar etiquetas semánticas a los distintos *tokens* del texto, transformando una secuencia de caracteres en información estructurada. Por ejemplo, una secuencia numérica como «12345» puede clasificarse como Número de Albarán, mientras que una expresión como «Tornillo M8» puede etiquetarse como Descripción de Artículo.

1. Entrada (Texto Plano procedente del OCR):

El proveedor Logística Sur suministró 50 unidades de Tornillo M8 el 12/05/2024 según el albarán 12345.

2. Salida (Texto Estructurado por el modelo NER):

El proveedor Logística Sur [PROVEEDOR] suministró 50 [CANTIDAD] unidades de Tornillo M8 [ARTÍCULO] el 12/05/2024 [FECHA] según el albarán 12345 [NUM.ALBARÁN] .

Figura 5: Ejemplo visual de la tarea NER. Dada una secuencia de texto plano, el modelo aísla los *tokens* relevantes y les asigna categorías semánticas predefinidas para estructurar la información administrativa.

En la actualidad, la inmensa mayoría de los modelos de PLN emplean arquitecturas basadas en *Transformers*, introducidas originalmente por Vaswani *et al.* (Vaswani y cols., 2017). La principal innovación de esta arquitectura radica en el mecanismo de autoatención (*self-attention*), que permite al modelo analizar simultáneamente las relaciones existentes entre todos los *tokens* de una secuencia. Gracias a ello, los *Transformers* son capaces de capturar dependencias contextuales de largo alcance y construir representaciones semánticas más ricas que las obtenidas mediante arquitecturas recurrentes tradicionales.

A pesar de la sofisticación de estos modelos lingüísticos, el análisis crítico de los enfoques en cascada basados en OCR y PLN revela una limitación estructural conocida como propagación de errores. Dado que el modelo de PLN opera exclusivamente sobre el texto transcrito, cualquier error cometido durante la fase de OCR pasa a formar parte de la entrada del sistema y puede afectar negativamente a las etapas posteriores de extracción y clasificación de información. Por ejemplo, la confusión de un dígito en un código de producto o la pérdida de un carácter alfanumérico pueden comprometer la correcta identificación de una entidad.

Asimismo, esta aproximación procesa el documento como una secuencia lineal de *to-*

kens, por lo que la información relativa a la disposición espacial de los elementos suele perderse o quedar insuficientemente representada. **Esta limitación resulta especialmente relevante en documentos logístico-industriales, donde la posición relativa de campos, tablas y bloques de información constituye una fuente de contexto esencial para interpretar correctamente el contenido del documento.**

2.2.2. Modelos basados en Layout y enfoques multimodales con lectura externa

Con el objetivo de mitigar la pérdida de contexto espacial inherente a los enfoques basados en OCR y PLN, surgió el paradigma de los modelos multimodales conscientes de la estructura documental (*layout-aware models*, en inglés). En el ámbito del ML, un modelo multimodal es una arquitectura capaz de procesar e integrar simultáneamente diferentes modalidades de información. **En el caso de la comprensión documental, estas modalidades incluyen el contenido textual extraído, las características visuales de la imagen y la disposición espacial de los elementos dentro del documento, permitiendo construir representaciones semánticas más completas y contextualizadas.**

El trabajo de Xu *et al.* (Xu y cols., 2020) supuso un hito relevante al introducir *LayoutLM*, la primera arquitectura de preentrenamiento diseñada para modelar conjuntamente las interacciones entre el contenido textual y la estructura espacial de los documentos. Como se muestra en la figura 6, *LayoutLM* extiende la arquitectura *Transformer* mediante la incorporación de *embeddings* de posición bidimensionales. En el contexto de las redes neuronales, un *embedding* consiste en una representación vectorial densa que permite transformar datos discretos, como palabras o coordenadas espaciales, en vectores numéricos adecuados para su procesamiento por el modelo.

En este caso, dichos vectores codifican las coordenadas de las cajas delimitadoras generadas por el sistema OCR, proyectándolas sobre un espacio bidimensional normalizado en el intervalo $[0, 1000]$. A diferencia de los *Transformers* convencionales, que emplean únicamente información posicional unidimensional para representar el orden secuencial de los *tokens*, *LayoutLM* incorpora explícitamente información espacial del documento. Gracias a ello, el mecanismo de autoatención puede modelar relaciones entre elementos teniendo en cuenta no solo su similitud semántica, sino también su posición relativa y organización geométrica dentro de la página.




Figura 6: Arquitectura del modelo *LayoutLM*. En este esquema se observa cómo los *embeddings* bidimensionales de la disposición espacial y de la imagen se integran en la arquitectura original de BERT (del inglés, *Bidirectional Encoder Representations from Transformers*). Estos *embeddings* posicionales propios de *LayoutLM* y las características visuales extraídas mediante la red *Faster R-CNN* trabajan conjuntamente para resolver las tareas posteriores de extracción de información (Xu y cols., 2020).

Esta línea de investigación evolucionó hacia modelos de tercera generación como *LayoutLMv3* (Huang, Lv, Cui, Lu, y Wei, 2022). ***LayoutLMv3* unifica las modalidades de texto e imagen mediante una arquitectura que prescinde de redes convolucionales pesadas para la extracción visual, adoptando la estrategia de segmentación de la imagen en parches lineales (en inglés, *patches*) popularizada por los ViT (del inglés, *Vision Transformers*).**

Para aprender de forma autónoma las relaciones entre estas modalidades, el modelo se preentrena bajo objetivos duales de enmascaramiento (*masking*, en inglés). En el ámbito del ML autosupervisado, el enmascaramiento es una técnica de entrenamiento que consiste en ocultar o corromper deliberadamente una fracción de los datos de entrada, exigiendo a la red neuronal que prediga y reconstruya la información faltante basándose exclusivamente en el contexto visible restante.

LayoutLMv3 aplica esta estrategia de forma simultánea en dos frentes: uno orientado al texto (MLM, del inglés *Masked Language Modeling*), donde se ocultan *tokens* aleatorios de la secuencia de palabras; y otro orientado a la imagen (MIM, del inglés *Masked Image Modeling*), donde se enmascaran parches concretos del diseño visual. **Este plan-**

teamiento obliga a la red a inferir tanto la información textual como la visual a partir del contexto multimodal circundante, desarrollando una comprensión semántica profunda de cómo interactúa el texto con su diseño estructural en el documento.

De manera más específica, tal y como se detalla en el esquema de la figura 7, *LayoutLMv3* se preentrena mediante objetivos de reconstrucción discreta de *tokens* aplicados al modelado de lenguaje enmascarado y al modelado de imagen enmascarada. Además, incorpora un objetivo de alineamiento entre palabras y parches (WPA, del inglés *Word-Patch Alignment*) para aprender la correspondencia entre modalidades, prediciendo si el parche de imagen asociado a una palabra textual ha sido enmascarado. En su arquitectura, la etiqueta “Seg” denota posiciones a nivel de segmento, mientras que [CLS], [MASK], [SEP] y [SPE] actúan como *tokens* especiales para orquestar la entrada multimodal.




Figura 7: Estructura y objetivos de preentrenamiento de *LayoutLMv3*. El modelo toma como entrada la proyección lineal de los parches de imagen y de los *tokens* de palabras, codificándolos en representaciones vectoriales contextualizadas mediante objetivos unificados de enmascaramiento intermodal (Huang y cols., 2022).

Para optimizar el rendimiento de estas redes en la extracción de tablas logísticas, arquitecturas avanzadas como *mmLayout* (Wang y cols., 2022) proponen la construcción de

grafos documentales multimodales. Como se ilustra en la figura 8, estos grafos permiten relacionar elementos de grano fino (palabras individuales y parches de imagen) con elementos de grano grueso (frases completas y regiones visuales salientes), mejorando la captura de la semántica jerárquica y reduciendo el número de parámetros de la red.




Figura 8: Arquitectura general del modelo *mmLayout*. El marco propuesto se estructura en tres componentes principales: **(a) Entrada multimodal de múltiple granularidad:** utiliza un método de agrupamiento (*clustering*, en inglés) para construir nodos visuales de grano grueso (*coarse-grained*, en inglés). **(b) Grafo documental multimodal:** modela las complejas relaciones entre los elementos multimodales de distinta granularidad presentes en el documento. **(c) Transformador multimodal (*mmLayout*):** extrae características semánticas mediante codificadores específicos para grano fino y grueso. Las características de grano fino se agregan siguiendo aristas de granularidad cruzada y se enriquecen mediante conocimiento contextual. Finalmente, ambas representaciones se fusionan para generar la predicción estructurada (Wang y cols., 2022).

Aunque estos modelos logran resultados sobresalientes en evaluaciones académicas, dependen enteramente de un OCR previo para extraer y localizar el texto. Esta dependencia penaliza la inferencia, sumando el coste del reconocimiento inicial al del complejo procesamiento multimodal posterior. Además, siguen arrastrando la vulnerabilidad intrínseca a los fallos del OCR, un problema crítico al procesar imágenes industriales degradadas, borrosas o de baja calidad.

2.2.3. Modelos generativos de traducción directa de imagen a texto (OCR-Free)

Para romper la dependencia de los componentes externos de OCR y simplificar sustancialmente el flujo de preprocesamiento, el estado del arte ha avanzado de forma decisiva hacia arquitecturas generativas de extremo a extremo (en inglés, *end-to-end*) libres de OCR. Un modelo a destacar dentro de este enfoque es *DONUT* (del inglés, *Document Understanding Transformer*) (Kim y cols., 2022). **Esta arquitectura elimina por completo el concepto de detección de caracteres individuales y reformula el problema de procesamiento documental como una tarea directa de traducción de imagen a texto estructurado.**

Tal y como demuestran sus autores empíricamente, este enfoque supera con creces a los *pipelines* tradicionales basados en OCR más modelos de lenguaje (como *LayoutLM*): reduce significativamente el consumo de memoria (143 MB frente a los más de 179 MB del enfoque clásico), acelera el tiempo de inferencia (1,2 frente a 1,7 segundos por imagen) y eleva la precisión global de extracción documental del 87 % al 94 %.

Estructuralmente, como se ilustra en el esquema de la figura 9, *DONUT* está compuesto por un codificador visual basado en la arquitectura *Swin Transformer*. Este módulo opera directamente sobre los píxeles de la imagen del documento completo a través de ventanas de atención locales desplazadas, capturando tanto los glifos de los caracteres como el diseño visual global de forma implícita en un mapa de características latentes densas.




Figura 9: Arquitectura general del modelo *DONUT*. El codificador visual mapea directamente la imagen del documento en representaciones vectoriales (*embeddings*). A partir de estas características codificadas, el decodificador genera una secuencia de *tokens* que se convierte de forma nativa en información estructurada (por ejemplo, bajo el formato JSON) (Kim y cols., 2022).

Este mapa latente es transferido a un decodificador de texto autorregresivo, basado en un *Transformer* lingüístico de tipo *BART* (del inglés, *Bidirectional and Auto-Regressive*

Transformers). El decodificador toma la representación visual abstracta y genera de forma directa, *token a token*, una secuencia de texto formateada nativamente en un esquema estructurado, típicamente JSON (del inglés, *JavaScript Object Notation*), donde cada etiqueta define la entidad semántica y su contenido correspondiente (por ejemplo, {"proveedor": "Multinacional SL", "total": "1450.50"}).

Estudios recientes en el ámbito de la extracción de información documental resaltan que esta aproximación libre de OCR exhibe una tolerancia superior frente al ruido visual localizado y a degradaciones físicas severas en el documento. Debido a que el decodificador lingüístico opera de manera autorregresiva y ha sido preentrenado específicamente en tareas de predicción secuencial (modelado de lenguaje causal) sobre corpus masivos, posee la capacidad de apoyarse en el contexto sintáctico para “reconstruir” semánticamente palabras borrosas, términos incompletos o caracteres distorsionados por pliegues en el papel que harían colapsar a un sistema tradicional.

Para ilustrar el impacto de esta tolerancia con datos empíricos, la investigación aplicada (Khallouli, Uddin, Sousa-Poza, Li, y Kovacic, 2025) implementó modelos basados en arquitecturas *Transformer*, combinados con técnicas de aumentación generativa de datos, para abordar una tarea industrial crítica: la digitalización y extracción de texto en planos de ingeniería naval obsoletos de la Marina estadounidense. Al enfrentarse a tipografías antiguas e imágenes severamente degradadas, los resultados demostraron que esta metodología logró elevar la precisión en el reconocimiento de palabras desde un deficiente rango del 60-70 %, obtenido mediante motores OCR comerciales de referencia, hasta superar el 90 %, validando su eficacia en entornos industriales con déficit de digitalización primaria.

A pesar de sus ventajas, investigaciones recientes sobre modelos multimodales libres de OCR (Liu y cols., 2024) advierten de una vulnerabilidad crítica: las alucinaciones semánticas. Al generar texto basándose en probabilidades, si el modelo se enfrenta a un dato numérico borroso o ambiguo, tiende a inventar («alucinar») un valor que cuadre lógicamente con el formato esperado (por ejemplo, un JSON), ignorando la imagen real. En la logística industrial, que el sistema invente un número de lote, una fecha de caducidad o una cantidad de material supone un riesgo inasumible, ya que puede provocar severos fallos de trazabilidad, descuadres de inventario y errores críticos en las auditorías.

Para mitigar este riesgo, la literatura reciente y, en particular, el estudio de (JI y cols., 2023), sugieren que el despliegue de estas arquitecturas en entornos de producción no puede

realizarse de forma directa (en inglés, *zero-shot*), aplicando el modelo directamente sobre una tarea específica sin haberle proporcionado ejemplos previos de entrenamiento en ese dominio concreto. **Resulta necesaria una fase de adaptación al dominio mediante ajuste fino (*fine-tuning*) sobre un conjunto de datos representativo del entorno operativo real.** Este proceso de reentrenamiento actúa como un mecanismo de anclaje, restringiendo la libertad probabilística del decodificador y forzando al modelo a alinear estrictamente sus predicciones con la casuística visual y estructural de los documentos específicos de la empresa, hipótesis que será evaluada empíricamente en la fase experimental de este trabajo.

2.2.4. Paradigmas de IA Documental y el dilema del despliegue en entornos industriales

Una vez analizadas las principales corrientes en la literatura científica, desde los sistemas en cascada hasta las arquitecturas generativas *OCR-Free* como *DONUT*, se evidencia que la transferencia de estos modelos al plano práctico de la ingeniería logística no depende únicamente de su precisión matemática. **Existe un dilema recurrente entre el uso de soluciones comerciales en la nube y el despliegue local (en inglés, *on-premise*) de modelos de código abierto.**

Para ofrecer una perspectiva global antes de evaluar su viabilidad en planta, la tabla 1 sintetiza las ventajas y los riesgos críticos de cada uno de los paradigmas tecnológicos descritos a lo largo de este estado del arte.

Tabla 1: Análisis comparativo de los paradigmas arquitectónicos en IA Documental

Paradigma	Entradas Requeridas	Ventajas Operativas	Limitaciones y Riesgos Críticos
Pipeline en Cascada (DBNet + CRNN + PLN)	Imagen de documento pura	- Bajo consumo de VRAM - Arquitectura modular auditable - Alta velocidad de inferencia local	- Propagación destructiva del error - Descarte total de la estructura geométrica y relaciones 2D
Multimodal Consciente del Layout (<i>LayoutLMv3</i> , <i>mmLayout</i>)	Imagen + Texto extraído + Coordenadas 2D	- Máxima precisión en estructuras tabulares densas - Fusión profunda de texto, geometría y parches visuales	- Dependencia absoluta de la calidad del OCR externo - Preprocesamiento complejo y coste de cómputo duplicado
Generativo OCR-Free (<i>DONUT</i>)	Imagen de documento pura	- Elimina el pipeline de OCR intermedio - Elevada tolerancia al ruido físico y arrugas en el papel	- Riesgo de alucinación semántica en valores numéricos - Baja velocidad de inferencia (decodificación autorregresiva)
Híbrido LLM Cloud (OCR Local + GPT Remoto)	Imagen digitalizada o Texto OCR	- Flexibilidad lingüística extrema - Adaptabilidad inmediata a nuevos formatos	- Violación de la soberanía del dato - Latencia impredecible y dependencia de conectividad externa

Con la llegada de los Grandes Modelos de Lenguaje (LLM, del inglés *Large Language Models*) y los modelos fundacionales multimodales, han surgido aproximaciones híbridas que combinan sistemas OCR con capacidades avanzadas de razonamiento lingüístico.

Un ejemplo es robustecer motores OCR locales mediante el postprocesamiento contextual de modelos generativos remotos basados en GPT, flexibilizando la extracción en entornos de manufactura (J. Park, Cho, Han, y Kim, 2025). Sin embargo, este enfoque centralizado basado en API externas colisiona frontalmente con las restricciones operativas reales de un entorno industrial sensible. Tal y como fundamenta el estudio (Ogrezeanu y cols., 2022) sobre ecosistemas del Internet Industrial de las Cosas (*IIoT*, del inglés Industrial Internet of Things), las plataformas logísticas modernas descartan por completo la dependencia de servicios comerciales en la nube debido a dos factores críticos:

- **Soberanía del dato y privacidad:** Los albaranes industriales contienen información estratégica de alta sensibilidad (identidades de clientes, volúmenes de compra, flujos de materiales y estructuras de precios pactados). Externalizar estos datos mediante llamadas a API controladas por terceros, ubicados frecuentemente fuera de la jurisdicción local, introduce riesgos inasumibles de ciberseguridad y expone a la organización a potenciales sanciones por incumplimiento de normativas de privacidad.
- **Continuidad operativa y latencia:** Las líneas de producción y los centros de distribución de alta cadencia exigen sistemas estables con latencias acotadas y una disponibilidad elevada. El núcleo de la operación logística no puede verse condicionado por la estabilidad de la conectividad externa ni por los costes variables asociados a los servicios en la nube.

Ante la inviabilidad de las soluciones propietarias remotas, esta investigación se enfoca exclusivamente en la evaluación empírica de modelos de código abierto capaces de ser desplegados, entrenados y ejecutados localmente.

2.3. Conclusiones del estado del arte

A pesar del notable dinamismo y los avances documentados en la literatura científica reciente dentro del campo de la IA Documental, la revisión del estado del arte pone de manifiesto varios desafíos que dificultan la transferencia de estos modelos desde el ámbito

académico hacia entornos de producción industrial. La mayoría de los trabajos publicados, así como los modelos preentrenados de referencia, basan su evaluación en conjuntos de datos académicos altamente estandarizados.

El primer vacío identificado radica en la escasez de estudios comparativos aplicados al procesamiento de documentos logísticos complejos bajo condiciones de degradación visual similares a las presentes en entornos industriales reales. La principal limitación para este tipo de investigaciones reside en la confidencialidad de los documentos utilizados en operaciones logísticas, lo que restringe la disponibilidad de conjuntos de datos públicos representativos. Como consecuencia, la literatura dispone de pocas evaluaciones realizadas sobre documentos con alta densidad tabular, relaciones clave-valor complejas y distintos niveles de deterioro visual.

El segundo vacío identificado corresponde a la ausencia de marcos de evaluación que integren simultáneamente la calidad de extracción, la robustez frente al ruido documental y la viabilidad computacional de los modelos. La investigación académica suele centrarse en métricas de precisión, prestando menor atención a aspectos relacionados con el consumo de recursos, la latencia o la posibilidad de despliegue en infraestructuras locales. Sin embargo, estos factores resultan determinantes para la adopción de soluciones de IA documental en entornos industriales.

Para dar respuesta a estos vacíos, la fase experimental de este trabajo propone la comparación de tres arquitecturas representativas de los paradigmas tecnológicos analizados en este capítulo:

- **Motor OCR Tradicional (*PP-OCR*):** Se implementará como línea base (*baseline*) metodológica para representar el enfoque clásico de extracción. Su inclusión está justificada por su extremada ligereza computacional y su consolidado despliegue actual en la industria, lo que permitirá acotar el umbral de rendimiento mínimo.
- **Modelo Multimodal en cascada (*LayoutLMv3*):** Se seleccionará para representar el estado del arte en la comprensión espacial basada en OCR. Su elección se fundamenta en su capacidad inigualable para modelar la geometría 2D del documento, permitiendo evaluar si su alto coste computacional compensa los errores de transcripción heredados del reconocimiento óptico previo.
- **Arquitectura Generativa *End-to-End* (*DONUT*):** Se implementará como el exponente disruptivo libre de dependencias externas (*OCR-free*). El objetivo es com-

probar empíricamente si su teórica robustez frente al ruido visual y su traducción directa a formatos estructurados superan el riesgo operacional de las alucinaciones semánticas.

Esta comparativa permitirá determinar qué arquitectura ofrece el mejor equilibrio entre robustez frente a la degradación visual, calidad de extracción y viabilidad de despliegue en entornos logísticos industriales.

3. Objetivos y Metodología de Trabajo

El presente trabajo se justifica plenamente por su orientación directa a resolver la brecha de conocimiento identificada, vinculando la investigación teórica en IA con las exigencias del tejido industrial. Ante la inaccesibilidad de albaranes reales por motivos de secreto comercial, este trabajo propone un diseño experimental riguroso utilizando facturas complejas como un aproximación estructuralmente equivalente, simulando computacionalmente las hostilidades del entorno logístico. La pregunta de investigación que articula este estudio se formula explícitamente en los siguientes términos:

¿Qué compromiso existe entre la precisión en la extracción semántica, la robustez frente a la degradación física documental, y el coste computacional en las principales arquitecturas abiertas de IA Documental aplicadas a documentos logísticos complejos bajo entornos de despliegue locales?

3.1. Objetivo general

El objetivo principal del presente trabajo es comparar el rendimiento de tres familias de arquitecturas de IA Documental de código abierto atendiendo a tres criterios clave (precisión semántica, robustez y coste computacional) en la extracción de información, utilizando facturas comerciales como aproximación estructural de albaranes bajo entornos de despliegue local.

Siguiendo las buenas prácticas metodológicas, este objetivo se ha definido en base a los criterios SMART:

- **S (Specific - Específico):** Comparar arquitecturas representativas de tres paradigmas (pipelines en cascada, multimodales conscientes del *layout* y generativos *OCR-Free*) sobre la tarea de KIE en documentos con alta densidad tabular.
- **M (Measurable - Medible):** La evaluación se cuantificará mediante métricas estándar (F_1 -Score, CER y ANLS), así como mediante indicadores de eficiencia computacional, incluyendo el consumo de CPU, RAM y VRAM, la latencia por documento y la degradación del rendimiento bajo distintos niveles de ruido visual.

- **A (Attainable - Alcanzable):** La investigación sorteó el obstáculo de la confidencialidad de los datos utilizando un *dataset* público de facturas y aplicando técnicas de aumento de datos (en inglés, *data augmentation*) para simular el deterioro en almacén.
- **R (Relevant - Relevante):** Proporciona al sector logístico una guía técnica empírica que da cumplimiento a los requisitos de soberanía del dato y latencia exigidos en operativas reales.
- **T (Time-Related - Con un tiempo determinado):** El trabajo se estructura en fases secuenciales de desarrollo y validación para su culminación dentro del calendario académico establecido.

3.2. Objetivos específicos

Para garantizar la consecución del objetivo general, se han establecido los siguientes objetivos específicos:

1. **Preparar el corpus documental:** Seleccionar un conjunto de datos público representativo de facturas complejas e implementar un *pipeline* de aumento de datos para simular degradaciones físicas (arrugas, ocultación parcial de información e iluminación deficiente).
2. **Despliegue de arquitecturas:** Implementar en un entorno local aislado las versiones de código abierto de los modelos seleccionados, garantizando el cumplimiento de los requisitos de soberanía del dato.
3. **Entrenamiento y ajuste:** Ejecutar procesos de transferencia de aprendizaje sobre el conjunto documental seleccionado para adaptar los modelos al dominio de aplicación.
4. **Evaluación y comparativa:** Someter los modelos a distintos niveles de degradación documental, registrando tanto el rendimiento de extracción como los recursos computacionales requeridos durante la inferencia.
5. **Desarrollo de un marco de decisión:** Elaborar una matriz comparativa que sintetice los principales compromisos entre precisión, robustez y coste computacional, facilitando la toma de decisiones tecnológicas en entornos logísticos industriales.

3.3. Metodología de trabajo

Este estudio adopta una metodología empírico-cuantitativa. **La investigación parte de la hipótesis de que las arquitecturas generativas de extremo a extremo (*end-to-end*) libres de OCR presentan un comportamiento más robusto frente a degradaciones visuales y ruido documental que los enfoques tradicionales basados en OCR.**

Con el fin de contrastar esta hipótesis, se lleva a cabo una **evaluación experimental controlada en un entorno computacional homogéneo, utilizando métricas cuantitativas que permiten analizar tanto la calidad de extracción de información como la eficiencia computacional de los modelos estudiados.**

El desarrollo del trabajo se articula en las siguientes fases secuenciales:

1. **Acondicionamiento y generación de datos:** Evaluación preliminar en entorno *zero-shot* utilizando el *dataset* público de recibos comerciales CORD (S. Park y cols., 2019a). Posteriormente, ante la confidencialidad de los datos reales, se implementa un motor propio para la creación de un *dataset* sintético logístico en español (5.000 documentos), aplicando un *pipeline* probabilístico de visión artificial (*Albumentations* (Buslaev y cols., 2020)) para inyectar degradaciones óptico-físicas severas.
2. **Implementación e integración de sistemas:** Desarrollo y despliegue de los *scripts* de ejecución en Python. Se configuran las clases, los tokenizadores y los cargadores de datos apoyándose en los marcos de código abierto *PyTorch* (Paszke y cols., 2019) y *Hugging Face* (Wolf y cols., 2020).
3. **Diseño experimental y ajuste fino (*fine-tuning*):** Se establece inicialmente una referencia de partida mediante la evaluación del motor tradicional *PaddleOCR*, que se mantiene sin reentrenamiento (*zero-shot*). Posteriormente, se aplica un proceso de adaptación al dominio (*fine-tuning*) sobre las arquitecturas avanzadas *LayoutLMv3* y *DONUT* utilizando el conjunto de datos sintético. Para reducir el riesgo de sobreajuste, el entrenamiento se valida mediante una partición fija del conjunto de datos (80 % entrenamiento, 10 % validación y 10 % prueba).
4. **Extracción empírica de métricas:** Ejecución de las inferencias sobre los conjuntos de prueba bajo condiciones de ruido incremental. Se extraen de forma automatizada las métricas a nivel de negocio (Precisión, *Recall* y *F1-Score*), las métricas de

tolerancia morfológica a nivel de carácter (CER y ANLS) y las métricas de huella computacional (latencia por documento y consumo de CPU, RAM y VRAM).

5. **Análisis crítico y síntesis de resultados:** Procesamiento estadístico de los datos empíricos recolectados, contrastando formalmente las ventajas y vulnerabilidades de cada enfoque (incluyendo el impacto de las alucinaciones semánticas) para dictaminar la viabilidad real de su despliegue en una PyME logística local.

4. Desarrollo de la Comparativa

El presente capítulo detalla la metodología de investigación, los conjuntos de datos y el diseño experimental definidos para evaluar de forma empírica la viabilidad de la automatización del KIE en el dominio de la logística industrial. Se establecen los recursos de datos empleados, los modelos seleccionados para la comparativa y las métricas de validación matemática.

A modo de síntesis, la tabla 2 expone los diferentes paradigmas arquitectónicos enfrentados en esta comparativa y sus dependencias fundamentales.

Tabla 2: Resumen de los modelos comparados y su paradigma de extracción.

Modelo	Paradigma	Dependencia OCR	Salida
<i>PaddleOCR</i>	Pipeline en cascada (Baseline)	Sí (Propio)	Campos por RegEx
<i>LayoutLMv3</i>	Clasificación de tokens (NER)	Sí (Tesseract)	Etiquetas BIO
<i>DONUT</i>	Seq2Seq (Visión→Texto)	No (End-to-End)	JSON estructurado

4.1. Bases de datos y análisis preliminar

En la literatura especializada predominan los enfoques de aprendizaje supervisado, por este motivo resulta imprescindible contar con conjuntos de datos rigurosamente etiquetados para el entrenamiento y la evaluación comparativa de las arquitecturas de IA Documental. En el contexto de este trabajo, **la obtención y preparación de los datos se aborda en dos fases secuenciales: una primera fase de evaluación teórica utilizando un conjunto de datos público de referencia académica, y una segunda fase de entrenamiento y validación aplicada mediante la generación de un conjunto de datos sintético propio.**

4.1.1. Evaluación en dominio público: Dataset CORD

Para establecer la línea base de rendimiento de los modelos propuestos y evaluar su comportamiento inicial frente a documentos estructurados, se ha seleccionado el conjunto de datos CORD (del inglés, *Consolidated Receipt Dataset for Post-OCR Parsing*) (S. Park y cols., 2019b). En la literatura científica reciente, CORD representa un referente estándar

para las tareas de KIE, estando compuesto por miles de imágenes de recibos y facturas comerciales con anotaciones detalladas a nivel de región y de texto. Un ejemplo representativo de los documentos incluidos en este conjunto de datos puede observarse en la figura 10.



Figura 10: Ejemplo de documento del dataset CORD (*Consolidated Receipt Dataset*), utilizado como referencia pública para la evaluación de tareas de KIE.

El análisis exploratorio de este conjunto de datos revela documentos con una alta densidad de información estructurada en pares clave-valor (como listados de artículos, cantidades, impuestos y totales) y disposiciones espaciales heterogéneas. Al pertenecer al dominio del comercio minorista (*retail*), CORD constituye un punto de partida adecuado para evaluar la capacidad inicial de los modelos en tareas de comprensión bidimensional y extracción de entidades.

Sin embargo, este conjunto de datos presenta limitaciones significativas pa-

ra abordar el caso específico de la logística industrial española, lo que motiva la creación de un corpus especializado. La principal limitación de CORD no reside en la calidad de las imágenes, susceptible de ser degradada artificialmente, sino en la estructura documental que representa. Los recibos comerciales carecen de elementos habituales en los albaranes logísticos, donde coexisten datos fiscales de emisor y receptor, múltiples direcciones de entrega, códigos de pedido, referencias cruzadas y otra información administrativa interrelacionada.

Asimismo, las líneas de detalle presentes en los documentos logísticos suelen incorporar descripciones técnicas extensas, referencias alfanuméricas de productos y unidades de medida específicas, características que apenas aparecen en los tickets de compra convencionales. **Estas diferencias estructurales y semánticas justifican la transición metodológica hacia la generación de un conjunto de datos sintético adaptado al dominio de la logística española.**

4.1.2. Generación del Dataset Sintético Logístico Industrial

Uno de los principales obstáculos para la digitalización de la cadena de suministro es la escasez de conjuntos de datos abiertos y representativos. Los albaranes y facturas reales contienen habitualmente información estratégica y datos de carácter personal protegidos tanto por el RGPD como por políticas de confidencialidad empresarial, lo que dificulta su publicación y utilización para el entrenamiento de modelos de aprendizaje profundo en entornos académicos.

Para superar esta limitación sin comprometer la validez experimental de la investigación, se ha diseñado e implementado un motor de generación de datos sintéticos de alta fidelidad. Este sistema permite la creación automatizada de un volumen escalable de documentos comerciales en español, garantizando la alineación exacta entre cada imagen generada y su correspondiente verdad de referencia (*ground truth*). De este modo, es posible disponer de un conjunto de datos amplio, controlado y completamente etiquetado, adaptado específicamente a las características documentales del sector logístico. La figura 11 muestra un ejemplo de albarán generado mediante este procedimiento, previo a la aplicación de las transformaciones de degradación empleadas en la fase de evaluación.

El conjunto de datos sintético se ha construido siguiendo directrices de ingeniería orientadas a garantizar el realismo semántico, visual y estadístico de los documentos generados:

- **Generación semántica:** Se ha integrado la librería *Faker* (Faraglia y cols., 2024), configurada con la localización española (`es_ES`), para generar entidades empresariales verosímiles, direcciones postales realistas, códigos de identificación fiscal (CIF) válidos y una taxonomía coherente de artículos logísticos, incluyendo elementos como palés, transpaletas, bobinas y cajas de cartón.
- **Renderizado documental:** Mediante la librería de procesamiento de imágenes *Pillow* (Clark y contributors, 2024), se ha diseñado una plantilla que reproduce la estructura visual habitual de documentos generados por sistemas de ERP. Con objeto de incrementar el realismo del conjunto de datos, se han incorporado elementos gráficos frecuentes en entornos empresariales, tales como códigos de barras, franjas tabulares sombreadas y textos legales en tamaño reducido. Esta estrategia permite exponer a los modelos a escenarios visuales más próximos a los documentos reales y favorece la discriminación entre información relevante y elementos accesorios.
- **Volumen y partición:** Se ha generado un corpus compuesto por 5.000 documentos sintéticos. Para garantizar la integridad de la evaluación experimental y minimizar el riesgo de sobreajuste, el conjunto de datos se ha dividido mediante una partición estática del 80 % para entrenamiento (4000 imágenes), 10 % para validación (500 imágenes) y 10 % para pruebas (500 imágenes), manteniendo una separación estricta entre las distintas fases del proceso de desarrollo y evaluación.

Albarán Generado (Logística Industrial)

 HERMANOS MARTORELL. CIF: ESG1963309f Urbanización Anselma Jurado 03617 Cantabria	ALBARÁN DE ENTREGA  Nº Doc: ALB-2020-30032 Fecha: 01/12/2024		
ENTREGAR A: CELESTINA OLLER-LAGUNA Rambla Celso Higueiras 8 Piso 8 12228 Zamora			
CANT	DESCRIPCIÓN	PRECIO U.	TOTAL
8	Bobina Cable Cobre 100m	47.56 €	380.48 €
30	Film Estirable Transparente	5.47 €	164.10 €
33	Caja Cartón Doble Canal	115.48 €	3810.84 €
7	Film Estirable Transparente	131.23 €	918.61 €
41	Bidón Aceite Motor 50L	78.61 €	3223.01 €

Firma y Sello del Receptor: Fecha: __/__/20__	<table><tr><td>Base Imponible:</td><td>8497.04 €</td></tr><tr><td>IVA (21%):</td><td>1784.38 €</td></tr><tr><td>TOTAL A PAGAR:</td><td>10281.42 €</td></tr></table>	Base Imponible:	8497.04 €	IVA (21%):	1784.38 €	TOTAL A PAGAR:	10281.42 €
Base Imponible:	8497.04 €						
IVA (21%):	1784.38 €						
TOTAL A PAGAR:	10281.42 €						

Aviso Legal: Documento mercantil sujeto a la Ley 15/1999 de Protección de Datos de Carácter Personal (LOPD). La mercancía viaja por cuenta y riesgo c

Figura 11: Ejemplo de albarán logístico generado por el motor sintético previo a la aplicación de ruido.

4.1.3. Simulación de condiciones operativas

Los albaranes utilizados en entornos logísticos reales rara vez se capturan en condiciones ideales. Durante su manipulación y transporte, estos documentos pueden presentar arrugas, manchas, desenfoque, variaciones de iluminación o defectos de impresión que dificultan su procesamiento automático.

Con el objetivo de evaluar la robustez de los modelos frente a estas condiciones operativas, se ha implementado un *pipeline* de aumento de datos (*data augmentation*) basado en la librería *Albumentations*. Esta herramienta proporciona un amplio conjunto de transformaciones capaces de simular de forma realista las degradaciones presentes en documentos físicos. La figura 12 muestra un ejemplo del resultado obtenido tras la aplicación de este proceso sobre una imagen sintética.

Las transformaciones se aplican de forma controlada para generar diferentes escenarios de dificultad y analizar el comportamiento de los modelos ante distintos niveles de degradación visual. De este modo, es posible cuantificar la pérdida de rendimiento asociada a condiciones de captura cada vez más adversas y determinar la capacidad de generalización de cada arquitectura en contextos próximos a los observados en entornos industriales reales. En particular, cada imagen sintética del corpus es sometida, de forma probabilística, a las siguientes transformaciones:

1. **Degradación del soporte documental:** Inserción de manchas, sombras irregulares y artefactos visuales, con el fin de simular el deterioro producido durante la manipulación y el transporte de documentos físicos. Estas transformaciones generan zonas parcialmente cubiertas sobre determinadas regiones del documento, reproduciendo condiciones habituales en entornos logísticos reales.
2. **Distorsión geométrica:** Aplicación de transformaciones elásticas y deformaciones de perspectiva para simular pliegues, dobleces y capturas fotográficas realizadas desde ángulos no perpendiculares al plano del documento.
3. **Ruido de captura digital:** Introducción de ruido gaussiano, desenfoque por movimiento y variaciones de brillo y contraste para reproducir las condiciones derivadas de la digitalización mediante cámaras de dispositivos móviles o escáneres en escenarios de iluminación no controlada.

La aplicación de este proceso de degradación controlada permite construir diferentes

escenarios de evaluación que reproducen condiciones operativas realistas. **De este modo, es posible analizar de forma sistemática la sensibilidad de los modelos frente a distintos tipos de deterioro documental y cuantificar su capacidad de mantener el rendimiento cuando la calidad visual de los documentos se degrada progresivamente.**




Figura 12: Ejemplos de albaranes sintéticos tras la aplicación del aumento de datos. Se aprecian dobleces, desenfoces y manchas superpuestas al texto comercial.

4.2. Selección de modelos para la comparativa

A partir del análisis crítico de la literatura expuesto en la sección 2.2, donde se presentaron los fundamentos teóricos y las principales arquitecturas de los diferentes paradigmas de la IA documental, en esta sección se delimitan los modelos concretos que formarán parte del diseño experimental.

Con el fin de obtener una comparativa equilibrada y representativa, se ha seleccionado una arquitectura de referencia para cada una de las tres familias tecnológicas identificadas en el estado del arte. Esta estrategia permite evaluar las principales aproximaciones de código abierto actualmente disponibles para tareas de KIE en entornos de despliegue local.

4.2.1. *PaddleOCR*

Como representante de los sistemas basados en *pipelines* en cascada, se ha implementado una solución fundamentada en el ecosistema *PaddleOCR*. Tal y como se justificó en el estado del arte, su arquitectura modular, compuesta por el detector de texto *DBNet++* y el reconocedor *SVTR*, constituye una de las soluciones de código abierto más maduras y eficientes para tareas de OCR documental.

La inclusión de *PaddleOCR* en este experimento tiene como objetivo establecer una línea base de referencia tanto en términos de rendimiento como de coste computacional. En el marco del diseño experimental, el modelo se evalúa en un escenario *zero-shot*, empleando directamente los pesos preentrenados proporcionados por sus desarrolladores sin realizar procesos adicionales de ajuste o adaptación sobre el conjunto de datos generado para este trabajo. Como consecuencia, su utilización no requiere fases de entrenamiento ni consumo adicional de memoria de vídeo (VRAM) asociado a la optimización de parámetros.

No obstante, *PaddleOCR* está diseñado principalmente para la detección y reconocimiento de texto. Aunque permite recuperar la posición espacial de cada fragmento reconocido, no incorpora de forma nativa mecanismos de comprensión documental orientados a la extracción de entidades semánticas complejas. En consecuencia, el proceso de KIE se ha implementado mediante un conjunto de expresiones regulares (RegEx, del inglés *Regular Expressions*) diseñadas para identificar patrones específicos dentro del texto extraído.

Esta aproximación híbrida permite evaluar empíricamente las limitaciones inherentes a los sistemas basados en reglas. En particular, resulta de interés analizar su comportamiento ante documentos con elevada variabilidad estructural, donde cambios en el formato, la disposición de los campos o la calidad visual pueden dificultar la correcta identificación de las entidades objetivo.

4.2.2. *LayoutLMv3*

Como representante de las arquitecturas multimodales conscientes de la estructura documental (*layout-aware*), se ha seleccionado el modelo *LayoutLMv3*. **A diferencia de los *pipelines* tradicionales, esta aproximación integra simultáneamente tres fuentes de información: el contenido textual reconocido, la disposición espacial**

de cada palabra, codificada mediante coordenadas bidimensionales de cajas delimitadoras, y las características visuales extraídas directamente de la imagen del documento.

Una de las particularidades de *LayoutLMv3* es que no incorpora un mecanismo OCR propio. Por ello, requiere una fase previa de procesamiento mediante un motor OCR externo, encargado de extraer las palabras presentes en el documento junto con sus coordenadas espaciales. Una vez obtenida esta información, el modelo puede combinar las modalidades textual, visual y espacial durante el proceso de inferencia.

En el marco de este trabajo, la extracción de información clave se plantea como una tarea de NER, representada mediante el esquema de etiquetado BIO (*Begin, Inside, Outside*). En este formato, cada token se clasifica como inicio de una entidad (*B*), continuación de una entidad (*I*) o elemento no perteneciente a ninguna entidad de interés (*O*), permitiendo identificar secuencias de palabras asociadas a campos como proveedor, dirección o importe total.

La inclusión de *LayoutLMv3* permite evaluar hasta qué punto la incorporación explícita de información espacial mejora la extracción de entidades en documentos logísticos. Asimismo, resulta especialmente interesante analizar su comportamiento bajo distintos niveles de degradación visual, donde los errores introducidos por la fase OCR pueden propagarse al resto del proceso de inferencia.

4.2.3. *DONUT*

Como representante del paradigma generativo *OCR-Free*, se ha considerado la arquitectura *DONUT*. Desde el punto de vista estructural, *DONUT* se compone de un codificador visual basado en *Swin Transformer* y un decodificador autorregresivo de lenguaje natural de tipo *BART*. Esta configuración permite modelar de forma conjunta la representación visual del documento y la generación secuencial de texto.

En el contexto del presente experimento, el tokenizador preentrenado del modelo se adapta mediante la incorporación de etiquetas semánticas específicas del dominio logístico (por ejemplo, `<proveedor>` o `<total>`). Estas etiquetas definen la estructura de la salida esperada y permiten asociar cada valor extraído con la entidad correspondiente. De este modo, la arquitectura genera directamente una secuencia estructurada en formato JSON a partir de la imagen de entrada.

La inferencia se realiza sin recurrir a etapas explícitas de OCR, produciendo la secuencia textual directamente a partir de las representaciones visuales aprendidas por el modelo. Como consecuencia, la lectura del documento y la extracción de información clave se integran en un único proceso de inferencia de extremo a extremo.

La inclusión de *DONUT* en este estudio permite evaluar el potencial de los enfoques generativos para la comprensión documental, así como analizar si la eliminación de la dependencia de un motor OCR externo se traduce en una mayor robustez frente a las degradaciones visuales introducidas durante la evaluación.

4.3. Entorno de experimentación

El diseño de un marco de evaluación comparativo requiere emplear unas condiciones de ejecución homogéneas para todas las arquitecturas analizadas. Dada la diversidad de los enfoques considerados, que abarcan desde sistemas basados en reglas hasta modelos multimodales de aprendizaje profundo, el entorno experimental se ha configurado de forma controlada con el objetivo de minimizar la influencia de factores externos y garantizar la comparabilidad de los resultados obtenidos.

4.3.1. Infraestructura de cómputo y aceleración gráfica

Los experimentos se han desarrollado en un entorno virtual acelerado por hardware proporcionado por la plataforma *Google Colaboratory*. Las principales características de la infraestructura utilizada son las siguientes:

- **Unidad de Procesamiento Gráfico (GPU): NVIDIA Tesla T4** basada en la arquitectura *Turing*, equipada con 16 GB de memoria GDDR6. Esta GPU proporciona soporte para operaciones aceleradas mediante núcleos *CUDA* y *Tensor*, permitiendo tanto el entrenamiento como la inferencia de modelos multimodales de gran tamaño en un entorno de recursos moderados.
- **Unidad Central de Procesamiento (CPU):** Procesador *Intel Xeon* asignado por la infraestructura de Google Colab, encargado de las tareas de preparación de datos, carga de imágenes, preprocesamiento documental y coordinación de las operaciones de entrenamiento e inferencia.

- **Memoria de Sistema (RAM):** Aproximadamente 12,7 GB de memoria RAM, utilizados para el almacenamiento temporal de los conjuntos de datos, estructuras de etiquetado y variables auxiliares necesarias durante la ejecución de los experimentos.

La elección de esta configuración responde al objetivo de evaluar la viabilidad práctica de las arquitecturas seleccionadas en un entorno de computación accesible, representativo de los recursos disponibles en pequeñas y medianas empresas que deseen desplegar soluciones de procesamiento documental sin necesidad de recurrir a infraestructuras especializadas de alto coste.

4.3.2. Ecosistema de software y dependencias base

Con el objetivo de garantizar la reproducibilidad de los experimentos, el entorno de ejecución se ha basado en una distribución de *Ubuntu Linux* junto con **Python 3.10**. Sobre esta base se han integrado tres ecosistemas de *software* especializados:

1. **PyTorch:** Utilizado como marco principal de aprendizaje profundo para el entrenamiento e inferencia de modelos *Transformer*, así como para la gestión de la aceleración mediante GPU.
2. **Hugging Face (Transformers, datasets, accelerate):** Proporciona herramientas de alto nivel para la experimentación con modelos multimodales. La librería *Transformers* se emplea para cargar arquitecturas y tokenizadores preentrenados, mientras que *datasets* facilita la gestión eficiente de los conjuntos de datos. Asimismo, se utiliza la API *Seq2SeqTrainer* para la ejecución de los procesos de entrenamiento y evaluación.
3. **PaddlePaddle y PaddleOCR:** Empleados para la implementación del enfoque basado en *pipeline*. PaddlePaddle actúa como marco de aprendizaje profundo subyacente, mientras que *PaddleOCR* proporciona los componentes necesarios para la detección y reconocimiento de texto.

Con el fin de obtener mediciones temporales consistentes y comparables entre arquitecturas, se incorporaron mecanismos de sincronización entre CPU y GPU antes de registrar los tiempos de inferencia. Esta precaución resulta especialmente relevante en entornos acelerados por hardware, donde numerosas operaciones se ejecutan de forma asíncrona. **De**

este modo, las métricas de latencia reportadas reflejan el tiempo real empleado en el procesamiento completo de cada documento.

4.3.3. Controles de reproducibilidad y aislamiento

Para garantizar la validez interna del estudio y la comparabilidad de los resultados obtenidos, se han aplicado diferentes mecanismos de control orientados a la reproducibilidad experimental:

- **Control de la aleatoriedad:** Se ha fijado una semilla global determinista (`seed = 42`) para todas las operaciones que implican componentes estocásticos, incluyendo la partición de los conjuntos de datos. De este modo, todas las arquitecturas se evalúan sobre la misma distribución de muestras y, en particular, sobre un conjunto de prueba idéntico.
- **Aislamiento de la fase de evaluación:** La inferencia se realiza de forma independiente al proceso de entrenamiento, cargando los pesos almacenados en los puntos de control (*checkpoints*) previamente persistidos. Esta estrategia garantiza una separación estricta entre entrenamiento y evaluación, evitando cualquier posible contaminación entre ambas fases.
- **Instrumentación unificada:** Se ha desarrollado un módulo común de evaluación encargado de registrar de forma homogénea las métricas de rendimiento, incluyendo la latencia de inferencia y el consumo de memoria de vídeo (VRAM). **Este procedimiento asegura que las mediciones obtenidas para *PaddleOCR*, *LayoutLMv3* y *DONUT* sean directamente comparables bajo las mismas condiciones experimentales.**

Este procedimiento asegura que las mediciones obtenidas para *PaddleOCR*, *LayoutLMv3* y *DONUT* sean directamente comparables bajo las mismas condiciones experimentales.

4.4. Diseño experimental y estrategia de optimización

El diseño experimental de este trabajo se estructura en dos fases consecutivas. La primera está orientada a establecer una línea base de rendimiento para cada uno de los paradigmas de IA documental considerados, mientras que la segunda se centra en la adaptación

al dominio logístico y en la evaluación de la robustez de los modelos frente a condiciones operativas realistas. Esta metodología permite analizar tanto el efecto del cambio de dominio como el impacto de las degradaciones visuales sobre el rendimiento de las distintas arquitecturas.

4.4.1. Fase 1: Evaluación inicial sobre CORD

La primera fase del diseño experimental tiene como objetivo evaluar el comportamiento de las arquitecturas en su estado preentrenado (*zero-shot*), es decir, sin realizar ningún tipo de ajuste sobre los datos específicos de esta investigación. Para ello, los tres modelos seleccionados se someten a una prueba de inferencia directa utilizando el conjunto de datos público CORD, descrito en la sección 4.1.1.

El proceso de evaluación en esta fase se desarrolla mediante un único escenario de prueba, que consiste en la inferencia directa sobre las muestras originales del conjunto CORD con el fin de estimar el rendimiento de cada arquitectura en condiciones controladas.

El propósito de esta fase no es resolver el problema específico de la logística industrial, sino establecer una línea base de rendimiento en un entorno homogéneo y ampliamente utilizado en la literatura científica. Los resultados obtenidos permiten comparar las capacidades iniciales de los modelos en un contexto estandarizado y sirven como referencia para cuantificar posteriormente el impacto del cambio de dominio y los beneficios derivados del proceso de adaptación al contexto logístico.

4.4.2. Fase 2: Adaptación al dominio y validación en entorno operativo

Una vez analizadas las limitaciones de los modelos en su estado preentrenado, la segunda fase del diseño experimental aborda la adaptación al dominio mediante técnicas de transferencia de aprendizaje. Para ello, se emplea el corpus sintético descrito en la sección 4.1.2, compuesto por 5.000 albaranes generados específicamente para este trabajo.

Con el fin de garantizar una comparación rigurosa entre modelos y evitar fenómenos de contaminación de datos, el corpus se divide mediante una partición estática: el 80 % de las muestras (4000 imágenes) se destina al entrenamiento, el 10 % (500 imágenes) a la validación del proceso de aprendizaje y el 10 % restante (500 imágenes) se reserva exclusivamente para la evaluación final, permaneciendo completamente aislado durante el desarrollo de los modelos.

Antes de detallar el proceso de optimización, resulta necesario justificar la exclusión de *PaddleOCR* de esta fase experimental. Al tratarse de un sistema orientado principalmente a la detección y reconocimiento de texto, la extracción de información clave depende de un postprocesamiento externo basado en expresiones regulares (*Regex*). Como consecuencia, la aplicación de técnicas de *fine-tuning* únicamente permitiría mejorar el rendimiento del OCR, sin incorporar mecanismos adicionales de comprensión documental ni de extracción semántica de entidades.

Por el contrario, tanto *LayoutLMv3* como *DONUT* incorporan mecanismos de aprendizaje capaces de modelar relaciones textuales, visuales y espaciales, permitiendo adaptar sus parámetros al dominio logístico mediante aprendizaje supervisado. Debido a sus diferencias arquitectónicas, el proceso de ajuste fino se implementa mediante dos estrategias específicas:

1. ***LayoutLMv3*, clasificación de *tokens*:** En esta arquitectura, la KIE se formula como una tarea de NER. Cada documento se representa mediante una combinación de texto, características visuales y coordenadas espaciales normalizadas de las palabras presentes en el albarán. El modelo aprende a clasificar cada token según el esquema BIO, asignando etiquetas como B-PROVEEDOR, I-PROVEEDOR o B-TOTAL.
2. ***DONUT*, generación imagen a secuencia:** En este caso, el ajuste fino se plantea como una tarea de secuencia a secuencia (*Seq2Seq*). El codificador visual *Swin Transformer* procesa directamente la imagen del documento, mientras que el decodificador genera de forma autorregresiva una representación estructurada de la información extraída. Durante el entrenamiento, los pesos del modelo se optimizan minimizando la pérdida de entropía cruzada con respecto a una secuencia objetivo. Para ello, cada documento se representa mediante una salida estructurada en formato JSON, donde los distintos campos se delimitan mediante etiquetas semánticas específicas. Por ejemplo, el valor del CIF del proveedor puede representarse mediante la secuencia `<cif_proveedor>B12345678 </cif_proveedor>`. De este modo, el modelo aprende a generar directamente una representación estructurada del documento, identificando de forma explícita el inicio y el final de cada entidad de interés.

Una vez completada la fase de adaptación al dominio sobre el corpus limpio, los modelos se evalúan inicialmente sobre el conjunto de prueba original

compuesto por 500 documentos reservados, estableciendo así una referencia de rendimiento en condiciones ideales.

Análisis de robustez frente a degradaciones documentales

Posteriormente, con el objetivo de analizar la robustez de las arquitecturas frente a las condiciones propias de los entornos reales, se generan nuevos conjuntos de evaluación a partir de dichas muestras mediante la aplicación controlada de degradaciones visuales utilizando la librería *Albumentations*. En concreto, se consideran cuatro escenarios de dificultad creciente, correspondientes a los niveles de ruido 0, 1, 2 y 3.

Es importante destacar que estas transformaciones se aplican exclusivamente durante la fase de evaluación. Por tanto, los modelos son entrenados únicamente con documentos limpios, mientras que las versiones degradadas se emplean para cuantificar el impacto que tienen factores como manchas, desenfoques, deformaciones geométricas o variaciones de iluminación sobre el rendimiento de la extracción de información. **Este planteamiento permite analizar de forma objetiva la sensibilidad de cada arquitectura a la degradación documental y evaluar su capacidad de mantenimiento del rendimiento en condiciones operativas cada vez más exigentes.**

Preparación de las etiquetas para *LayoutLMv3*

Durante la adaptación de *LayoutLMv3* al dominio logístico se identificaron diversas discrepancias entre la verdad de referencia y los *tokens* generados por el OCR externo (Tesseract). **Para garantizar la correcta asignación de etiquetas durante el entrenamiento, fue necesario incorporar varios mecanismos de preprocesamiento orientados a homogeneizar la representación de la información.:**

- **Normalización de formatos numéricos:** Inicialmente se observaron inconsistencias al comparar valores numéricos almacenados en la verdad de referencia con los textos extraídos por el OCR. Mientras que los ficheros JSON utilizaban habitualmente el formato decimal propio de programación (por ejemplo, 1210.5), el OCR generaba valores siguiendo la notación europea (por ejemplo, 1.210,50). Para evitar errores de correspondencia, se implementó un proceso previo de normalización que convirtió todas las representaciones numéricas a un formato canónico común.
- **Generación de etiquetas de continuación:** Se garantizó la correcta asignación de

etiquetas I- dentro del esquema BIO. Este aspecto resulta especialmente importante para entidades compuestas por múltiples palabras, como nombres de proveedores, direcciones o descripciones de artículos, ya que permite representar correctamente su extensión y facilita el aprendizaje de sus límites por parte del modelo.

Selección de hiperparámetros

El ajuste fino y la selección de hiperparámetros de las arquitecturas evaluadas estuvo condicionado por las limitaciones de memoria gráfica (VRAM) disponibles en el entorno experimental.

La configuración original del modelo está diseñada para procesar documentos de alta resolución (2560×1920 píxeles), lo que supone una elevada demanda de recursos durante la extracción y transformación de características visuales. Dado que esta resolución excedía la capacidad práctica de la infraestructura utilizada, fue necesario adaptar el procesamiento de entrada para garantizar la viabilidad del entrenamiento. La resolución de los documentos se normalizó a 1280×960 píxeles, reduciendo de forma significativa el consumo de memoria asociado al codificador visual *Swin Transformer* sin comprometer la legibilidad de los elementos documentales relevantes para la tarea de extracción de información. Esta decisión constituyó un requisito imprescindible para posibilitar el ajuste fino del modelo bajo las restricciones de hardware establecidas para el estudio.

Asimismo, durante las fases preliminares se evaluaron distintas estrategias orientadas a optimizar el uso de la memoria gráfica, incluyendo el empleo del optimizador Adafactor y configuraciones basadas en media precisión de 16 bits (FP16). Las pruebas realizadas mostraron que determinadas combinaciones orientadas a maximizar el ahorro de memoria introducían problemas de estabilidad numérica durante el proceso de optimización, dificultando la convergencia del modelo. Como consecuencia, se descartó el uso de dichas configuraciones y se adoptó una estrategia basada en el optimizador AdamW junto con Precisión Mixta Automática (AMP, del inglés *Automatic Mixed Precision*), que permitió mantener las ventajas de la computación en 16 bits sin comprometer la estabilidad del entrenamiento.

Las limitaciones computacionales del entorno experimental, basado en una única GPU NVIDIA Tesla T4 con 16 GB de VRAM, también condicionaron el proceso de selección de hiperparámetros. En lugar de recurrir a procedimientos exhaustivos de búsqueda automática, como *Grid Search* o *Random Search*, se optó por una exploración heurística

manual de los principales parámetros de entrenamiento. Este proceso permitió acotar rangos adecuados para la tasa de aprendizaje (*Learning Rate*), el decaimiento de pesos (en inglés *Weight Decay*) y el tamaño de lote (en inglés *Batch Size*), buscando un equilibrio entre estabilidad, consumo de recursos y rendimiento del modelo.

La configuración final se diseñó para mantener un tamaño de lote efectivo global (en inglés *Effective Batch Size*) de 8 imágenes por iteración en ambas arquitecturas, garantizando unas condiciones de entrenamiento homogéneas y comparables. En el caso de *DONUT*, esta configuración se alcanzó mediante el empleo de AdamW, AMP y la técnica de puntos de control de gradientes (en inglés *Gradient Checkpointing*), combinados con un tamaño de lote físico de 2 imágenes y 4 pasos de acumulación de gradientes. Por su parte, *LayoutLMv3* se configuró con un tamaño de lote físico de 4 imágenes y 2 pasos de acumulación, manteniendo igualmente un tamaño de lote efectivo de 8.

Las diferencias en la configuración de entrenamiento entre ambas arquitecturas responden a sus características estructurales. Mientras que *DONUT* procesa la imagen completa mediante un modelo generativo de secuencia a secuencia, *LayoutLMv3* aborda el problema como una tarea de clasificación de *tokens*, combinando información textual, visual y espacial previamente extraída por el OCR. Esta diferencia reduce significativamente los requisitos de memoria de *LayoutLMv3*, permitiendo utilizar tamaños de lote físicos superiores y prescindir de técnicas adicionales de optimización de memoria como *Gradient Checkpointing*. Del mismo modo, las pruebas realizadas sobre el conjunto de validación mostraron un comportamiento más estable con una tasa de aprendizaje de 2×10^{-5} y sin regularización mediante *Weight Decay*, configuración que fue finalmente adoptada para el ajuste fino del modelo.

Adicionalmente, ambos modelos compartieron una longitud máxima de secuencia fijada en 512 *tokens*. Esta limitación permitió controlar el consumo de memoria durante el entrenamiento, especialmente en *LayoutLMv3*, cuya arquitectura basada en mecanismos de atención es particularmente sensible al incremento de la longitud de las secuencias. Los hiperparámetros definitivos utilizados durante la fase de transferencia de aprendizaje se recogen en la tabla 3.

Tabla 3: Configuración final de hiperparámetros utilizada para el ajuste fino de *DONUT* y *LayoutLMv3*. Los valores seleccionados corresponden a los parámetros de entrenamiento empleados en la fase de adaptación al dominio, optimizados heurísticamente bajo restricciones de memoria gráfica.

Hiperparámetro	<i>DONUT</i>	<i>LayoutLMv3</i>
Checkpoint Base	DONUT-base-finetuned-cord-v2	<i>LayoutLMv3</i> -finetuned-cord
Longitud Máx. Secuencia	512 <i>tokens</i>	512 <i>tokens</i>
Optimizador	AdamW (<code>adamw_torch</code>)	AdamW (<code>adamw_torch</code>)
Tasa de Aprendizaje (<i>Learning Rate</i>)	4×10^{-5}	2×10^{-5}
Decaimiento de Pesos (<i>Weight Decay</i>)	0,01	0,0
<i>Batch Size</i> (por GPU)	2	4
<i>Gradient Accumulation Steps</i>	4	2
<i>Batch Size</i> Efectivo Global	8	8
Épocas de Entrenamiento (<i>Epochs</i>)	5	5
Precisión de Entrenamiento	Mixta Automática (FP16)	Mixta Automática (FP16)
<i>Gradient Checkpointing</i>	Activado	Desactivado

4.5. Protocolo y métricas de evaluación

La evaluación de arquitecturas de IA documental en entornos industriales no puede limitarse a la comparación exacta entre las predicciones generadas y los valores de referencia. La variabilidad introducida por los procesos de digitalización y la complejidad estructural característica de los documentos logísticos hacen necesaria la utilización de métricas que evalúen tanto la calidad de la extracción como la eficiencia computacional de los modelos. **Por ello, se ha definido un protocolo de evaluación que abarca desde el alineamiento de las predicciones hasta el análisis de los costes computacionales asociados al entrenamiento y la inferencia.**

4.5.1. Correspondencia entre predicciones y referencias

Antes de calcular las métricas de evaluación, es necesario establecer una correspondencia entre las predicciones generadas por el modelo y los valores de referencia. Este problema resulta especialmente relevante en las líneas de detalle de los albaranes, donde las arquitecturas pueden alterar el orden de las filas o generar un número diferente de registros como consecuencia de omisiones o errores de extracción.

Para abordar esta situación, se ha implementado un algoritmo de emparejamiento iterativo voraz (en inglés *greedy matching*) basado en la similitud textual del campo descripción. El procedimiento consta de las siguientes etapas:

1. **Normalización del texto:** Las descripciones de referencia y las predichas se convierten a minúsculas y se eliminan espacios redundantes.
2. **Cálculo de similitud:** Se calcula la similitud entre cada par de descripciones utilizando una medida derivada de la distancia de Levenshtein normalizada:

$$\text{Sim}(G_k, P_k) = 1,0 - \frac{\text{DistanciaLevenshtein}(G_k, P_k)}{\max(|G_k|, |P_k|)} \quad (1)$$

3. **Emparejamiento:** Cada línea de referencia se asocia con la predicción que presenta la mayor similitud, siempre que esta supere un umbral mínimo de aceptación ($\tau = 0,5$). Una vez establecida la correspondencia, ambas filas quedan excluidas de futuras asignaciones.

La utilización de una medida de similitud normalizada y la selección de un umbral de aceptación de $\tau = 0,5$ se fundamentan en las prácticas de evaluación empleadas en tareas de comprensión documental y lectura robusta, adoptadas en competiciones como ST-VQA (Biten y cols., 2019) y DocVQA (Mathew, Karatzas, y Jawahar, 2021). Este umbral permite compensar pequeñas discrepancias textuales derivadas del ruido documental, manteniendo al mismo tiempo un criterio suficientemente restrictivo para evitar emparejamientos incorrectos.

4. **Gestión de elementos no emparejados:** Las filas predichas sin correspondencia se contabilizan como falsos positivos (*FP*), mientras que las filas de referencia que no encuentran una predicción válida se contabilizan como falsos negativos (*FN*).

Una vez completado el proceso de alineamiento, las métricas de evaluación se calculan sobre los pares de registros emparejados, considerando tanto el campo descriptivo como el resto de entidades asociadas a cada línea de detalle.

4.5.2. Métricas de eficacia de extracción

Una vez emparejados los datos, el rendimiento de las arquitecturas se evalúa mediante métricas orientadas a medir tanto la similitud textual entre las predicciones y los valores

de referencia como la capacidad de extracción de entidades relevantes. **Para ello, se emplean métricas basadas en la distancia de edición de Levenshtein.**

$$D(i, j) = \begin{cases} i & \text{si } j = 0 \\ j & \text{si } i = 0 \\ D(i-1, j-1) & \text{si } x_i = y_j \\ 1 + \min \begin{cases} D(i-1, j) \\ D(i, j-1) \\ D(i-1, j-1) \end{cases} & \text{si } x_i \neq y_j \end{cases} \quad (2)$$

donde $D(i, j)$ representa la distancia de edición mínima entre los prefijos de longitud i y j de las cadenas x e y , respectivamente. La definición recursiva contempla cuatro situaciones:

- Si $j = 0$, la única forma de transformar una cadena de longitud i en una cadena vacía consiste en eliminar sus i caracteres, por lo que $D(i, 0) = i$.
- Si $i = 0$, se requieren j inserciones para generar la cadena objetivo, de modo que $D(0, j) = j$.
- Si los caracteres actuales coinciden ($x_i = y_j$), no es necesaria ninguna operación adicional y la distancia coincide con la obtenida para los prefijos anteriores, es decir, $D(i-1, j-1)$.
- Si los caracteres son diferentes ($x_i \neq y_j$), la distancia se obtiene añadiendo una operación de edición al coste mínimo entre tres alternativas: eliminación ($D(i-1, j)$), inserción ($D(i, j-1)$) o sustitución ($D(i-1, j-1)$).

En consecuencia, la distancia de Levenshtein equivale al número mínimo de inserciones, eliminaciones y sustituciones necesarias para transformar una cadena en otra.

La **Tasa de Error de Caracteres (CER)** cuantifica el grado de discrepancia entre la cadena predicha y la de referencia a nivel de carácter. Su cálculo se basa en el número mínimo de inserciones (I), sustituciones (S) y eliminaciones (D) necesarias para transformar la predicción en la cadena objetivo, normalizado respecto a la longitud total de la referencia (N):

$$CER = \frac{S + D + I}{N} \quad (3)$$

Un valor de CER igual a cero indica una coincidencia exacta entre ambas cadenas, mientras que valores crecientes reflejan un mayor número de errores de transcripción.

Complementariamente, se emplea la métrica de **ANLS** (Biten y cols., 2019), ampliamente utilizada en tareas de comprensión documental. Esta métrica permite valorar positivamente predicciones que presentan pequeñas discrepancias textuales atribuibles a errores de OCR o a degradaciones visuales del documento (por ejemplo, la confusión entre una letra l y un dígito 1):

$$ANLS = \begin{cases} 1 - \frac{\text{DistanciaLevenshtein(Predicción, Real)}}{\max(|\text{Predicción}|, |\text{Real}|)} & \text{si Similitud} \geq \tau \\ 0 & \text{en caso contrario} \end{cases} \quad (4)$$

Para evaluar la capacidad de las arquitecturas para extraer entidades semánticamente relevantes, se emplean métricas clásicas de recuperación de información basadas en los recuentos de verdaderos positivos (VP), falsos positivos (FP) y falsos negativos (FN). Un verdadero positivo corresponde a una entidad correctamente identificada, un falso positivo a una predicción incorrecta o inexistente en la referencia, y un falso negativo a una entidad presente en la referencia que no ha sido extraída por el modelo.

- **Precisión:** Mide la proporción de entidades extraídas que son correctas. Esta métrica refleja la capacidad del modelo para minimizar la generación de predicciones erróneas (*FP*).

$$Precision = \frac{VP}{VP + FP} \quad (5)$$

- **Recall:** Mide la proporción de entidades de referencia que han sido recuperadas correctamente. Esta métrica evalúa la capacidad del modelo para minimizar las omisiones (*FN*).

$$Recall = \frac{VP}{VP + FN} \quad (6)$$

Con el objetivo de sintetizar ambas perspectivas en una única medida, se emplea el **F1-Score**, definido como la media armónica entre la Precisión y el Recall:

$$F_1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (7)$$

Esta métrica proporciona una valoración equilibrada del rendimiento del modelo, especialmente en escenarios donde existe desbalance entre clases o entre el número de entidades presentes en las distintas categorías evaluadas.

4.5.3. Estrategias de agregación estadística de métricas

Con el fin de proporcionar una visión representativa del rendimiento global de las arquitecturas evaluadas, las métricas descritas anteriormente se agregan mediante dos enfoques complementarios:

- **Micro- F_1 :** Se calcula a partir del recuento global de verdaderos positivos, falsos positivos y falsos negativos de todas las entidades evaluadas. Como consecuencia, las categorías con un mayor número de instancias, como las líneas de detalle, tienen una influencia proporcionalmente mayor en el resultado final.
- **Macro- F_1 :** Se obtiene calculando el F_1 de cada entidad de forma independiente y promediando posteriormente los valores resultantes. Este enfoque asigna el mismo peso a todas las categorías, independientemente de su frecuencia de aparición, permitiendo evaluar de forma más equilibrada el comportamiento del modelo sobre el conjunto de entidades consideradas.

La utilización conjunta de ambas métricas permite distinguir entre el rendimiento global del sistema y la consistencia de dicho rendimiento entre las diferentes entidades presentes en el documento.

4.5.4. Métricas de eficiencia computacional

Además del rendimiento de extracción, la evaluación de las arquitecturas considera los recursos computacionales requeridos durante su ejecución. Esta perspectiva resulta especialmente relevante en escenarios de despliegue local, donde las limitaciones de hardware pueden condicionar la viabilidad operativa de las soluciones analizadas. Para ello, se monitorizan los siguientes indicadores:

- **Utilización de CPU:** Porcentaje medio de ocupación del procesador durante la ejecución del modelo. Esta métrica permite cuantificar la carga computacional transferida al sistema anfitrión durante la inferencia.

- **Consumo de RAM** (del inglés, *Random Access Memory*): Cantidad máxima de memoria principal utilizada durante la ejecución del modelo, expresada en megabytes (MB) o gigabytes (GB).
- **Consumo de VRAM** (del inglés, *Video Random Access Memory*): Cantidad máxima de memoria gráfica utilizada durante la ejecución del modelo, expresada en megabytes (MB) o gigabytes (GB).
- **Latencia por documento**: Tiempo necesario para procesar un documento completo durante la inferencia, expresado en segundos por documento (*s/doc*).

5. Resultados y Análisis Comparativo

Este capítulo presenta y analiza los resultados empíricos obtenidos tras la ejecución de los experimentos descritos en el capítulo 4. **El objetivo fundamental es evaluar el rendimiento de las arquitecturas seleccionadas en tareas de KIE, analizar el impacto de la adaptación al dominio logístico y cuantificar su comportamiento frente a distintos niveles de degradación documental.** Con este propósito, los resultados se estructuran en tres bloques complementarios:

1. **Evaluación base sobre CORD:** Análisis del rendimiento inicial de los modelos en un conjunto de datos público de referencia y libre de degradaciones adicionales. Esta fase permite establecer una línea base común y comparar el comportamiento de las arquitecturas antes de cualquier adaptación al dominio logístico.
2. **Evaluación sobre el dominio logístico-industrial español:** Análisis del rendimiento de *LayoutLMv3* y *DONUT* tras la adaptación al dominio mediante el corpus sintético desarrollado en este trabajo. La evaluación se realiza tanto sobre documentos limpios como bajo distintos niveles de degradación visual.
3. **Análisis comparativo global:** Síntesis de los resultados obtenidos, integrando conjuntamente las métricas de eficacia de extracción, robustez frente al ruido documental y eficiencia computacional de las distintas arquitecturas.

Para garantizar una interpretación homogénea de los resultados, el análisis se aborda desde tres perspectivas complementarias. En primer lugar, los indicadores *Micro-F1* y *Macro-F1* permiten evaluar la capacidad de extracción de entidades considerando tanto el rendimiento global como el comportamiento sobre campos específicos. En segundo lugar, las métricas *CER* y *ANLS* cuantifican la fidelidad textual de las predicciones y su sensibilidad a las degradaciones visuales. Por último, las métricas de eficiencia computacional permiten valorar la viabilidad práctica de cada aproximación en escenarios de despliegue industrial, considerando aspectos como la latencia de inferencia y el consumo de memoria.

5.1. Evaluación base sobre el dataset CORD

Antes de abordar la evaluación sobre el conjunto de datos de albaranes logísticos españoles, se diseñó un experimento preliminar utilizando el dataset público CORD. **El objetivo de esta prueba es establecer una línea base de rendimiento en un entorno controlado, evaluando el comportamiento de los modelos antes de enfrentarse al dominio logístico específico considerado en este trabajo.**

Para este experimento se evaluó la extracción de un único campo crítico: el importe total `total.total_price`, sobre una muestra de prueba de 95 recibos. La configuración de los modelos fue la siguiente:

- ***PaddleOCR***: Utilizado como sistema de referencia basado en reconocimiento óptico de caracteres y extracción mediante expresiones regulares.
- ***LayoutLMv3* y *DONUT***: Se emplearon los modelos distribuidos por sus autores, previamente ajustados sobre el conjunto de datos CORD.
- Adicionalmente, se evaluó ***LayoutLMv3*** bajo un escenario de *Golden OCR*, donde el texto y las coordenadas espaciales suministrados al modelo proceden directamente de las anotaciones de referencia. Esta configuración elimina los errores introducidos por el OCR y permite medir la capacidad de comprensión documental de la arquitectura en condiciones ideales.

5.1.1. Resultados de cuantitativos de la extracción de información clave

Los resultados cuantitativos del experimento base se detallan en la tabla 4.

Modelo	<i>F1-Score</i>	Precision	<i>Recall</i>	CER	ANLS
<i>PaddleOCR</i>	67.4 %	67.4 %	67.4 %	0.244	0.674
<i>LayoutLMv3</i>	67.1 %	96.1 %	51.6 %	0.484	0.516
<i>DONUT</i>	98.9 %	100.0 %	97.9 %	0.021	0.979

Tabla 4: Resultados cuantitativos de la extracción de información clave para el campo `total_price` en el conjunto de datos CORD (entorno sin ruido visual).

Como se observa en la Tabla 4, los resultados evidencian diferencias sustanciales entre los paradigmas de extracción evaluados.

PaddleOCR establece una línea base de rendimiento del 67.4 % de *F1-Score*. ***LayoutLMv3*** obtiene un resultado prácticamente equivalente (67.1 %), aunque presenta un marcado desequilibrio entre Precisión (96.1 %) y *Recall* (51.6 %). Este resultado indica la presencia de un número elevado de falsos negativos, es decir, entidades presentes en el documento que el modelo no logró recuperar durante la inferencia. Entre los errores observados destacan confusiones entre determinados campos con características similares, como *subtotal* y *total*. Dado que el experimento se realizó utilizando un escenario de *Golden OCR*, donde el texto suministrado al modelo procede directamente de las anotaciones de referencia, la pérdida de rendimiento observada no puede atribuirse a errores de reconocimiento óptico. **Por tanto, los resultados sugieren que las principales dificultades de la arquitectura se encuentran en la etapa de clasificación y comprensión documental, más que en la calidad de la información textual de entrada.**

Por su parte, ***DONUT*** alcanza un *F1-Score* del 98.9 %, superando ampliamente al resto de arquitecturas evaluadas. Al abordar la extracción de información mediante un enfoque generativo de extremo a extremo, el modelo procesa conjuntamente el contenido textual y la estructura global del documento durante la generación de la respuesta. Esta capacidad le permite resolver con mayor precisión las relaciones entre entidades y desambiguar correctamente campos de naturaleza similar, como los valores agregados del documento. **Como resultado, *DONUT* alcanza una Precisión del 100 % y un *Recall* del 97.9 %, reflejando un comportamiento notablemente más equilibrado que el observado en las arquitecturas basadas en clasificación de *tokens*.**

5.1.2. Análisis de Eficiencia Computacional

Los resultados de eficacia obtenidos por ***DONUT*** deben interpretarse conjuntamente con su coste computacional. Como muestra la tabla 5, la mejora en las métricas de extracción viene acompañada de un incremento significativo en la latencia y el consumo de memoria respecto a las demás arquitecturas evaluadas.

LayoutLMv3 se posiciona como la arquitectura más eficiente en términos de latencia y consumo de memoria de vídeo. Este comportamiento puede atribuirse a su naturaleza de modelo *Transformer* basado exclusivamente en un codificador (*encoder*), que permite procesar y clasificar simultáneamente todos los *tokens* de entrada en una única pasada de inferencia.

Modelo	Latencia (s/doc)	CPU (%)	VRAM (MB)	RAM (MB)
<i>PaddleOCR</i>	0.247	97.7	0.0 (Solo CPU)	2932.1
<i>LayoutLMv3</i>	0.050	82.1	541.3	3278.4
<i>DONUT</i>	0.891	85.4	1944.5	3415.5

Tabla 5: Costes computacionales de inferencia sobre la muestra de 95 recibos.

Por el contrario, *DONUT* presenta una latencia significativamente superior (0,891 segundos por documento, aproximadamente 18 veces mayor) y un mayor consumo de VRAM. Esta diferencia se explica por su arquitectura de tipo *encoder-decoder*, en la que la salida se genera de forma autorregresiva mediante un proceso secuencial de decodificación *token* a *token*. Como consecuencia, el coste computacional de la inferencia resulta considerablemente más elevado que en arquitecturas basadas únicamente en codificadores.

5.2. Evaluación sobre el dominio logístico-industrial español

En este apartado se presentan y analizan los resultados obtenidos por *LayoutLMv3* y *DONUT* tras el proceso de adaptación al dominio logístico-industrial español.

5.2.1. Modelo *LayoutLMv3*

El primer paradigma evaluado en esta segunda fase del estudio corresponde a la arquitectura multimodal *LayoutLMv3*. Una vez finalizado el proceso de adaptación al dominio, su rendimiento se evaluó sobre el conjunto de prueba completo, formado por 500 documentos. El modelo obtuvo un *Micro-F1* global del 92.2 % y un *Macro-F1* del 84.6 %.

La diferencia observada entre ambas métricas evidencia un comportamiento heterogéneo entre las distintas entidades evaluadas. Mientras que el elevado valor de *Micro-F1* indica un buen rendimiento global en el conjunto de extracción, el menor valor de *Macro-F1* revela que existen determinadas categorías cuya identificación resulta más compleja para el modelo. En consecuencia, aunque *LayoutLMv3* demuestra una elevada capacidad para extraer la mayoría de los campos presentes en los albaranes, su desempeño no es uniforme en todas las entidades, especialmente en aquellas cuya identificación depende en mayor medida de la estructura visual del documento, la disposición espacial de la información o la variabilidad existente entre plantillas.

Resultados cuantitativos y cualitativos de la extracción de información clave

La tabla 6 resume el rendimiento de *LayoutLMv3* para cada una de las entidades evaluadas. Las filas corresponden a los distintos campos del albarán, agrupados según su función dentro del documento (cabecera, líneas de detalle y totales), mientras que las columnas recogen las métricas de extracción (Precisión, *Recall* y *F1-Score*), las métricas de fidelidad textual (CER y ANLS) y el número de instancias disponibles para cada entidad en el conjunto de prueba.

Campo	Precision	Recall	F1-Score	CER	ANLS	Instancias
<i>Cabecera</i>						
numero_albaran	99.7 %	99.6 %	99.6 %	0.002	0.997	500
fecha	98.3 %	98.0 %	98.1 %	0.006	0.994	500
proveedor.cif	80.3 %	58.8 %	67.9 %	0.283	0.717	500
proveedor.nombre	33.0 %	23.2 %	27.3 %	0.424	0.575	500
proveedor.direccion	65.7 %	65.6 %	65.7 %	0.016	0.984	500
proveedor.ciudad	100.0 %	100.0 %	100.0 %	0.000	1.000	500
cliente.nombre	90.2 %	88.6 %	89.4 %	0.042	0.956	500
cliente.direccion	74.0 %	74.0 %	74.0 %	0.053	0.946	500
cliente.ciudad	48.1 %	38.2 %	42.6 %	0.245	0.758	500
<i>Líneas (Tabla)</i>						
lineas.descripcion	98.5 %	98.5 %	98.5 %	0.001	0.999	2791
lineas.cantidad	99.3 %	95.0 %	97.1 %	0.048	0.950	2791
lineas.precio_unitario	99.2 %	96.6 %	97.9 %	0.030	0.970	2791
lineas.total_linea	99.0 %	98.2 %	98.6 %	0.012	0.987	2791
<i>Totales</i>						
subtotal	100.0 %	98.6 %	99.3 %	0.014	0.986	500
iva_21	99.8 %	99.0 %	99.4 %	0.008	0.992	500
total	99.4 %	97.2 %	98.3 %	0.023	0.977	500

Tabla 6: Resultados cuantitativos y cualitativos de la KIE con la arquitectura *LayoutLMv3*.

Al analizar estas métricas desagregadas por campo, se observa un rendimiento generalmente sobresaliente en las diferentes secciones del documento. Sin embargo, determinados campos presentan una mayor dificultad de extracción, lo que explica la diferencia observada entre los valores de *Micro-F1* y *Macro-F1*.

Los resultados cuantitativos ponen de manifiesto la eficacia de la arquitectura multimodal *LayoutLMv3* tras su adaptación al dominio logístico. La combinación de información textual, espacial y visual permite identificar con gran precisión las entidades financieras y numéricas presentes en los documentos. Campos especialmente relevantes para el procesamiento documental, como las líneas de pedido y los importes agregados (*subtotal*, *iva_21* y *total*), alcanzan valores de F1 superiores al 97.9 %, acompañados de tasas de error de carácter (CER) prácticamente residuales. Asimismo, la Precisión y el *Recall* mantienen un comportamiento equilibrado en estas categorías, lo que indica que el modelo no solo identifica correctamente la información relevante, sino que también recupera la mayor parte de las entidades presentes en los documentos.

Sin embargo, el análisis por campo revela limitaciones significativas en determinados atributos de cabecera, como *proveedor.nombre* (27.3 % F1) o *cliente.ciudad* (42.6 % F1). Estas reducciones de rendimiento parecen estar relacionadas con errores introducidos durante la fase de OCR. En aquellos casos en los que nombres, direcciones u otros campos textuales aparecen visualmente agrupados, el OCR puede fusionar múltiples entidades lógicas en una misma región de texto. Como consecuencia, *LayoutLMv3* recibe información espacial ambigua, dificultando la correcta asignación de los *tokens* a sus respectivas categorías y provocando un aumento de falsos negativos que penaliza especialmente la métrica Macro-F1.

Robustez frente al Ruido

Uno de los objetivos fundamentales de esta investigación consiste en analizar la capacidad de las arquitecturas evaluadas para mantener su rendimiento ante documentos degradados. Con este fin, *LayoutLMv3* fue sometido a una batería de pruebas bajo diferentes niveles de deterioro visual generados artificialmente, permitiendo cuantificar el impacto que la pérdida progresiva de calidad documental ejerce sobre la KIE.

El nivel 0 representa la condición de referencia sin degradaciones adicionales, mientras que los niveles 1, 2 y 3 incorporan transformaciones de intensidad progresivamente creciente basadas en deterioro documental, distorsiones geométricas y ruido de captura digital,

simulando escenarios cada vez más exigentes desde el punto de vista operativo.

La tabla 7 resume el comportamiento global de *LayoutLMv3* bajo los distintos escenarios de degradación visual considerados. Cada fila representa un nivel de ruido, desde la condición de referencia sin degradaciones adicionales (Nivel 0) hasta el escenario de máxima severidad (Nivel 3). Por su parte, las columnas recogen las métricas de eficacia de extracción (Precisión, *Recall* y *F1-Score*), las métricas de fidelidad textual (CER y ANLS) y la latencia media de inferencia por documento. El análisis conjunto de estos indicadores permite cuantificar tanto la pérdida de precisión como el impacto computacional asociado al deterioro progresivo de la calidad documental.

Nivel de Ruido	Precisión	<i>Recall</i>	<i>F1-Score</i>	CER	ANLS	Latencia (s)
Nivel 0 (Base)	86.5 %	83.1 %	84.6 %	0.075	0.924	0.10
Nivel 1	79.0 %	67.7 %	72.2 %	0.203	0.795	3.43
Nivel 2	70.8 %	56.9 %	63.3 %	0.270	0.726	3.55
Nivel 3 (Máximo)	64.2 %	46.8 %	53.6 %	0.362	0.630	3.69

Tabla 7: Evolución de las métricas globales de *LayoutLMv3* bajo distintas condiciones de degradación visual.

Los resultados evidencian que el incremento del ruido sintético degrada notablemente el rendimiento del modelo. El Macro-F1 desciende desde el 84.6 % en el escenario base hasta el 53.6 % en el nivel de ruido máximo (Nivel 3). Asimismo, la tasa de error de caracteres (CER) aumenta de 0.075 a 0.362.




Figura 13: Evolución simétrica de la precisión y el *Recall* frente a la degradación visual en la arquitectura *LayoutLMv3*.

Como ilustra la figura 13, el deterioro visual afecta simultáneamente a la Precisión y al *Recall*. La Precisión cae 22.3 puntos porcentuales (del 86.5 % al 64.2 %), mientras que el *Recall* se reduce en 36.3 puntos (del 83.1 % al 46.8 %). Esta degradación conjunta indica que la pérdida de calidad documental no solo incrementa la omisión de entidades válidas, sino también la generación de clasificaciones incorrectas.

Este comportamiento pone de manifiesto la sensibilidad de las arquitecturas basadas en un flujo secuencial OCR+KIE frente a la degradación visual de los documentos. A medida que aumenta el nivel de ruido, la calidad de la información textual y espacial suministrada al clasificador se deteriora progresivamente, dificultando la correcta identificación de las entidades de interés. Como consecuencia, se observa un incremento simultáneo de Falsos Positivos y Falsos Negativos, lo que repercute negativamente tanto en la Precisión como en el *Recall*.

Eficiencia y costes computacionales

La evaluación concluye con el análisis del coste computacional asociado a *LayoutLMv3*. La adaptación al dominio requirió una fase previa de procesamiento OCR de 16.068,97 s (4,4 h), seguida de 9.385,86 s (2,6 h) correspondientes al ajuste fino de la arquitectura, alcanzando un consumo máximo de 8,07 GB de VRAM. **En conjunto, la preparación de los datos y el entrenamiento del modelo demandaron aproximadamente 7 horas de cómputo.**

Nivel de Ruido	Latencia (s/doc)	CPU (%)	VRAM (MB)	RAM (MB)
Nivel 0 (Base)	0.10	96.8	2531.5	3135.9
Nivel 1	3.431	14.4	2531.5	3148.6
Nivel 2	3.554	14.3	2531.5	3158.5
Nivel 3 (Máximo)	3.692	14.1	2531.5	3159.9

Tabla 8: Coste computacional de *LayoutLMv3* durante la evaluación de robustez bajo distintos niveles de degradación visual.

Durante la fase de inferencia, *LayoutLMv3* presenta un comportamiento claramente diferenciado según el estado de la canalización de procesamiento. Cuando los resultados del OCR se encuentran previamente calculados y disponibles en caché (*caché caliente*), el *Transformer* multimodal procesa cada documento en un tiempo medio de 0,10 s. Sin

embargo, en los escenarios con degradación visual (niveles 1 a 3), donde es necesario ejecutar nuevamente la etapa OCR sobre cada imagen, la latencia aumenta hasta 3,69 s por documento.

A pesar de este incremento, el consumo de recursos durante la inferencia permanece contenido, registrándose un máximo de 2.531,5 MB de VRAM y 3.135,9 MB de memoria RAM. **Estos resultados indican que la arquitectura puede operar dentro de los límites de hardware habitualmente disponibles en entornos industriales, sin requerir aceleradores gráficos de gama alta para su despliegue.**

Análisis del rendimiento y limitaciones del modelo

Los resultados obtenidos sitúan a *LayoutLMv3* como una arquitectura altamente eficaz para la KIE en documentos logísticos. Sin embargo, el análisis conjunto de las métricas de rendimiento y robustez pone de manifiesto dos limitaciones inherentes a su flujo de procesamiento:

- **Dependencia del OCR:** *LayoutLMv3* requiere la existencia previa de un proceso de reconocimiento óptico que proporcione el texto y las coordenadas espaciales de entrada. Como consecuencia, cualquier información que no sea correctamente detectada o transcrita durante esta fase queda excluida del proceso de inferencia. Esta dependencia limita la capacidad del modelo para recuperar información afectada por degradaciones visuales severas, ya que únicamente puede operar sobre los *tokens* generados por el OCR.
- **Sensibilidad a errores de segmentación espacial:** La calidad de las predicciones depende directamente de la correcta delimitación de las regiones textuales. Cuando el OCR fusiona varias entidades en una misma caja delimitadora o asigna coordenadas imprecisas a determinados fragmentos de texto, la representación espacial suministrada al modelo pierde precisión. Este fenómeno puede dificultar la correcta clasificación de entidades próximas y contribuir a la degradación observada en campos complejos, como determinados atributos de proveedor o cliente.

5.2.2. Modelo *DONUT*

Finalmente, se evalúa la arquitectura multimodal *DONUT* tras su proceso de adaptación al dominio logístico. Su rendimiento se analizó sobre el conjunto de prueba completo,

compuesto por 500 documentos. El modelo obtuvo un *Micro-F1* global del 84.3 % y un *Macro-F1* del 85.7 %.

La proximidad entre los valores de *Micro-F1* y *Macro-F1* indica un comportamiento notablemente homogéneo entre las distintas entidades evaluadas. La reducida diferencia entre los valores de *Micro-F1* y *Macro-F1* sugiere que el rendimiento del modelo se mantiene relativamente estable a través de las diferentes categorías analizadas, sin que existan campos específicos que penalicen de forma significativa el resultado global. En consecuencia, los resultados apuntan a una capacidad de extracción equilibrada en las distintas secciones del documento, independientemente de la naturaleza textual, visual o estructural de las entidades consideradas.

Resultados cuantitativos y cualitativos de la extracción de información clave

La tabla 9 presenta los resultados obtenidos por *DONUT* para cada uno de los campos evaluados. Las filas corresponden a las diferentes entidades presentes en el albarán, agrupadas según su función dentro del documento (cabecera, líneas de detalle y totales), mientras que las columnas recogen las métricas de extracción (Precisión, *Recall* y *F1-Score*), las métricas de fidelidad textual (CER y ANLS) y el número de instancias disponibles para cada entidad en el conjunto de prueba.

Al analizar las métricas desagregadas por campo, se observa un comportamiento relativamente homogéneo entre las distintas categorías, en consonancia con la proximidad existente entre los valores globales de *Micro-F1* y *Macro-F1*.

Los resultados cuantitativos muestran una diferencia clara entre la Precisión y el *Recall* del modelo. La Precisión supera el 98 % en la mayoría de los campos y alcanza el 100 % en entidades como `fecha`, `proveedor.ciudad`, `cliente.direccion`, `cliente.ciudad` y `lineas.descripcion`. Estos resultados indican que las predicciones incorrectas son poco frecuentes y que, cuando el modelo genera una entidad, esta suele corresponderse con la información correcta presente en el documento.

Por el contrario, el *Recall* presenta una variabilidad superior, con valores comprendidos entre el 67.4 % y el 80.8 %. Este comportamiento sugiere que la principal fuente de error no radica en la generación de valores erróneos, sino en la omisión de entidades válidas durante el proceso de extracción. En consecuencia, el rendimiento del modelo se ve penalizado principalmente por la presencia de falsos negativos.

Campo	Precision	Recall	F1-Score	CER	ANLS	Instancias
<i>Cabecera</i>						
numero.albaran	93.2 %	74.4 %	82.8 %	0.216	0.784	500
fecha	100.0 %	80.6 %	89.3 %	0.194	0.806	500
proveedor.cif	98.3 %	79.2 %	87.7 %	0.196	0.804	500
proveedor.nombre	98.8 %	79.2 %	87.9 %	0.202	0.796	500
proveedor.direccion	98.7 %	78.8 %	87.7 %	0.202	0.798	500
proveedor.ciudad	100.0 %	80.6 %	89.3 %	0.194	0.806	500
cliente.nombre	98.3 %	79.4 %	87.8 %	0.193	0.807	500
cliente.direccion	100.0 %	80.6 %	89.3 %	0.194	0.806	500
cliente.ciudad	100.0 %	80.8 %	89.4 %	0.192	0.808	500
<i>Líneas (Tabla)</i>						
lineas.descripcion	100.0 %	71.8 %	83.6 %	0.282	0.718	2720
lineas.cantidad	98.9 %	71.4 %	82.9 %	0.285	0.714	2720
lineas.precio_unitario	98.6 %	71.4 %	82.8 %	0.284	0.715	2720
lineas.total_linea	98.0 %	70.8 %	82.2 %	0.287	0.713	2720
<i>Totales</i>						
subtotal	98.3 %	70.8 %	82.3 %	0.284	0.717	500
iva_21	98.5 %	67.4 %	80.0 %	0.320	0.681	500
total	99.2 %	76.6 %	86.5 %	0.230	0.770	500

Tabla 9: Resultados cuantitativos y cualitativos de la KIE con la arquitectura *DONUT*

Las métricas de similitud textual muestran una tendencia coherente con la observada en las métricas de extracción. Los valores de ANLS oscilan entre 0.681 y 0.808, mientras que la CER varía entre 0.192 y 0.320. Los mejores resultados se concentran en varios campos de cabecera, como `fecha`, `proveedor.ciudad` o `cliente.ciudad`, que registran simultáneamente elevados valores de ANLS y bajas tasas de CER. Por el contrario, las mayores dificultades aparecen en determinadas entidades asociadas a las líneas de detalle y a los importes fiscales, particularmente en `iva_21`, donde se observan los valores más desfavorables de CER (0.320) y ANLS (0.681). **Este comportamiento sugiere que la**

extracción de información repetitiva y estructuralmente densa continúa siendo uno de los principales desafíos de la arquitectura.

Robustez frente al Ruido

Uno de los objetivos fundamentales de esta investigación consiste en analizar la capacidad de las arquitecturas evaluadas para mantener su rendimiento ante documentos degradados. Con este fin, *DONUT* fue sometido a una batería de pruebas bajo diferentes niveles de deterioro visual generados artificialmente, permitiendo cuantificar el impacto que la pérdida progresiva de calidad documental ejerce sobre la KIE.

El nivel 0 representa la condición de referencia sin degradaciones adicionales, mientras que los niveles 1, 2 y 3 incorporan transformaciones de intensidad progresivamente creciente basadas en deterioro documental, distorsiones geométricas y ruido de captura digital, simulando escenarios cada vez más exigentes desde el punto de vista operativo.

La tabla 10 resume el comportamiento global de *DONUT* bajo los distintos escenarios de degradación visual considerados. Cada fila representa un nivel de ruido, desde la condición de referencia sin degradaciones adicionales (Nivel 0) hasta el escenario de máxima severidad (Nivel 3). Por su parte, las columnas recogen las métricas de eficacia de extracción (Precisión, *Recall* y *F1-Score*), las métricas de fidelidad textual (CER y ANLS) y la latencia media de inferencia por documento. El análisis conjunto de estos indicadores permite cuantificar tanto la pérdida de precisión como el impacto computacional asociado al deterioro progresivo de la calidad documental.

Nivel de Ruido	Precisión	<i>Recall</i>	<i>F1-Score</i>	CER	ANLS	Latencia (s)
Nivel 0 (Base)	98.8 %	68.9 %	81.5 %	0.300	0.700	1.80
Nivel 1	96.6 %	59.1 %	73.6 %	0.391	0.609	1.79
Nivel 2	92.5 %	49.7 %	64.5 %	0.482	0.516	1.88
Nivel 3 (Máximo)	90.6 %	40.5 %	56.0 %	0.568	0.430	2.10

Tabla 10: Evolución de las métricas globales de *DONUT* bajo distintas condiciones de degradación visual.

Los resultados muestran que la degradación visual tiene un impacto significativo sobre el rendimiento de *DONUT*. El *F1-Score* desciende progresivamente desde el 81.5 % en la condición de referencia hasta el 56.0 % en el escenario de máxima

degradación. De forma paralela, la tasa de error de caracteres (CER) aumenta de 0.300 a 0.568, mientras que la similitud ANLS disminuye de 0.700 a 0.430, evidenciando una pérdida progresiva de fidelidad textual a medida que aumenta la severidad del ruido.

El análisis detallado de las métricas revela que esta degradación está asociada principalmente a una reducción del *Recall*. Mientras que la Precisión se mantiene en valores elevados, descendiendo únicamente de 98.8 % a 90.6 %, el *Recall* experimenta una caída mucho más pronunciada, pasando de 68.9 % a 40.5 %. Este comportamiento indica que, bajo condiciones de deterioro documental, el modelo conserva una elevada capacidad para generar predicciones correctas cuando identifica una entidad, pero aumenta considerablemente el número de entidades omitidas durante el proceso de extracción. Como consecuencia, la degradación del rendimiento global se encuentra más relacionada con el incremento de falsos negativos que con la generación de información incorrecta.




Figura 14: Evolución de la precisión y el *Recall* frente a la degradación visual en el modelo *DONUT*.

Desde el punto de vista estructural, el modelo mantuvo una tasa del 0.00 % de archivos JSON inválidos en todos los escenarios evaluados. Este resultado indica que, aunque la degradación visual afecta negativamente a la capacidad de extracción de información, no compromete la generación de salidas sintácticamente válidas. En consecuencia, **las pérdidas de rendimiento observadas se deben principalmente a errores u omisiones en el contenido extraído y no a fallos en la estructura de las respuestas generadas.**

Eficiencia y costes computacionales

El análisis de eficiencia computacional de *DONUT* permite evaluar el coste asociado tanto al proceso de adaptación al dominio como a la fase de inferencia. El ajuste fino del modelo requirió un total de 14.173s (3,9h) de entrenamiento, alcanzando un pico de consumo de 8,25 GB de VRAM.

La tabla 11 resume el comportamiento computacional de la arquitectura bajo los distintos escenarios de degradación visual. Cada fila corresponde a un nivel de ruido diferente, mientras que las columnas recogen la latencia media de inferencia por documento y los principales indicadores de consumo de recursos hardware (CPU, VRAM y RAM).

Nivel de Ruido	Latencia (s/doc)	CPU (%)	VRAM (MB)	RAM (MB)
Nivel 0 (Base)	1.80	96.8	1521.9	1868.4
Nivel 1	1.79	99.1	1521.4	1854.8
Nivel 2	1.88	99.7	1521.4	1827.3
Nivel 3 (Máximo)	2.10	99.1	1521.4	1856.0

Tabla 11: Coste computacional de *DONUT* durante la evaluación de robustez bajo distintos niveles de degradación visual.

Como puede observarse, el deterioro visual tiene un impacto reducido sobre los requerimientos computacionales del modelo. La latencia de inferencia se mantiene relativamente estable, pasando de 1.80s por documento en el escenario de referencia a 2.10s bajo el máximo nivel de degradación. De forma análoga, el consumo de memoria gráfica permanece prácticamente constante en torno a 1.5 GB de VRAM, mientras que la memoria RAM fluctúa de forma marginal entre los distintos escenarios evaluados.

Estos resultados indican que la degradación documental afecta principalmente a la calidad de la información extraída, pero no modifica de forma significativa el coste computacional del proceso de inferencia. Desde una perspectiva operativa, la arquitectura presenta un comportamiento estable en términos de consumo de recursos incluso bajo condiciones de deterioro visual severo.

Análisis del rendimiento y limitaciones del modelo

Aunque el modelo generó salidas estructuralmente válidas para la totalidad de los documentos evaluados (0,00 % de archivos JSON inválidos), el análisis de las métricas de extracción revela diversas limitaciones asociadas a su comportamiento durante la generación de las respuestas.

- **Diferencia entre precisión y *recall*:** *DONUT* presenta una diferencia consistente entre Precisión y *Recall*. Mientras que la Precisión supera el 97 % en la mayoría de los campos, los valores de *Recall* son sensiblemente inferiores, lo que indica que el modelo rara vez genera información incorrecta, pero tiende a omitir parte del contenido presente en el documento. En consecuencia, la principal fuente de error observada corresponde a la aparición de falsos negativos más que a la generación de predicciones erróneas.
- **Dificultades en entidades repetitivas y densamente estructuradas:** Los rendimientos más bajos se observan en los campos asociados a las líneas de producto y a determinados importes agregados. El campo *iva_21*, por ejemplo, alcanza un *Recall* del 67,4 % en el escenario base, mientras que las entidades pertenecientes a las líneas de detalle muestran resultados sistemáticamente inferiores a los obtenidos en los campos de cabecera. Este comportamiento sugiere que la arquitectura encuentra mayores dificultades en regiones del documento que contienen información repetitiva, alta densidad de entidades o estructuras tabulares complejas, donde la generación secuencial de la salida resulta más exigente.

5.3. Análisis Comparativo Global

Tras la evaluación individual de cada arquitectura, este apartado integra los resultados obtenidos con el fin de proporcionar una visión comparativa de los distintos enfoques analizados. Para ello, se contrastan *PaddleOCR*, *LayoutLMv3* y *DONUT* en términos de eficacia de extracción, robustez frente a la degradación documental y eficiencia computacional. Este análisis permite identificar las principales ventajas, limitaciones y ámbitos de aplicación de cada paradigma en el contexto logístico industrial.

5.3.1. Análisis comparativo de la extracción de información clave

La tabla 12 sintetiza los resultados más representativos obtenidos durante el estudio. Las filas corresponden a las arquitecturas evaluadas, mientras que las columnas recogen el *F1-Score* global alcanzado en tres escenarios distintos: la evaluación inicial *zero-shot* sobre el conjunto CORD (Fase 1), el rendimiento obtenido tras la adaptación al dominio logístico en condiciones ideales de captura (Fase 2, Nivel 0) y el comportamiento bajo el escenario de degradación visual más severo considerado en el estudio (Fase 2, Nivel 3). Esta comparación permite analizar simultáneamente la capacidad de generalización inicial de los modelos, su grado de especialización tras el ajuste fino y su resistencia frente al deterioro documental.

Arquitectura	Fase 1 (CORD)	Fase 2 (Nivel 0)	Fase 2 (Nivel 3)
<i>PaddleOCR + RegEx</i>	67.4 %	No aplica	No aplica
<i>LayoutLMv3</i>	67.1 %	84.6 %	53.6 %
<i>DONUT</i>	98.9 %	81.5 %	56.0 %

Tabla 12: Resumen comparativo del rendimiento global *F1-Score* en escenarios base, dominio logístico ideal y degradación máxima.

Los resultados reflejan diferencias sustanciales entre los paradigmas evaluados. La solución basada en *PaddleOCR + RegEx* obtuvo un rendimiento de referencia del 67.4 % de *F1-Score* en la evaluación *zero-shot* sobre CORD. Al tratarse de un sistema fundamentado en OCR y reglas heurísticas, su inclusión en el estudio tiene como finalidad proporcionar una línea base clásica para la tarea de extracción de información. A diferencia de las arquitecturas neuronales, este enfoque no dispone de un mecanismo de adaptación mediante *fine-tuning*, por lo que no participó en la evaluación sobre el dominio logístico desarrollada durante la Fase 2.

Las arquitecturas neuronales, por el contrario, evidenciaron una notable capacidad de adaptación al dominio objetivo. *LayoutLMv3* experimentó la mejora más acusada tras el proceso de ajuste fino, incrementando su *F1-Score* desde un 67.1 % hasta un 84.6 % en el escenario sin degradación. Estos resultados ponen de manifiesto la eficacia de sus representaciones multimodales para capturar las características estructurales y semánticas propias de los albaranes logísticos. No obstante, esta ganancia en especialización se vio acompañada de una mayor sensibilidad al deterioro visual,

reduciéndose su rendimiento hasta un 53.6 % bajo las condiciones de degradación más severas.

Por su parte, *DONUT* obtuvo el mejor resultado en la evaluación inicial sobre CORD, alcanzando un *F1-Score* del 98.9 %. Tras la adaptación al dominio logístico, la arquitectura mantuvo un rendimiento elevado (81.5 %), confirmando su capacidad para abordar documentos con características significativamente diferentes a las observadas durante su entrenamiento original. Bajo condiciones de degradación extrema, *DONUT* alcanzó un *F1-Score* del 56.0 %, superando ligeramente el resultado obtenido por *LayoutLMv3*. Este comportamiento sugiere una mayor robustez frente a la pérdida progresiva de calidad visual de los documentos.


En conjunto, los resultados evidencian que la adaptación al dominio logístico permite explotar eficazmente el potencial de las arquitecturas neuronales para la KIE. Asimismo, se observa una diferenciación clara entre ambos enfoques: mientras *LayoutLMv3* alcanza el mejor rendimiento en condiciones ideales, *DONUT* presenta una degradación más moderada ante escenarios visualmente adversos. Estas diferencias reflejan los compromisos inherentes a cada paradigma de procesamiento documental y ponen de manifiesto la influencia que ejerce la arquitectura sobre la capacidad de generalización y la robustez operacional del sistema.

Análisis desagregado del rendimiento por entidad


El análisis de las métricas desagregadas por entidad permite complementar la evaluación global de las arquitecturas y estudiar su comportamiento sobre los distintos campos del documento.

La figura 15 muestra el *F1-Score* obtenido por *LayoutLMv3* y *DONUT* para cada una de las entidades evaluadas en el escenario sin degradaciones visuales. Asimismo, se representan los valores globales de *Micro-F1* y *Macro-F1*, permitiendo contextualizar el rendimiento individual de cada campo respecto al comportamiento general del modelo.

Como puede observarse en la figura 15, ambas arquitecturas presentan distribuciones de rendimiento claramente diferenciadas. En el caso de *LayoutLMv3*, el *F1-Score* muestra una elevada dispersión entre entidades, con valores próximos al 100 % en campos como `proveedor.ciudad`, `subtotal`, `iva_21` o las distintas entidades asociadas a las líneas de pedido, mientras que otros campos, como `proveedor.nombre` o `cliente.ciudad`, presentan reducciones significativas de rendimiento. Esta variabilidad explica la diferencia



a) Rendimiento de *LayoutLMv3*



b) Rendimiento de DONUT

Figura 15: Desglose comparativo del *F1-Score* por entidad extraída en el escenario de referencia.

observada entre el *Micro-F1* (92.2 %) y el *Macro-F1* (84.6 %), indicando que el modelo obtiene resultados excelentes en determinadas entidades, pero encuentra mayores dificultades en otras categorías específicas.

Por el contrario, *DONUT* presenta una distribución mucho más uniforme. Los valores de F1 se concentran en un intervalo relativamente estrecho, comprendido aproximadamente entre el 80 % y el 90 %, sin observarse caídas tan pronunciadas como las registradas por *LayoutLMv3*. Como consecuencia, los índices globales de *Micro-F1* (84.3 %) y *Macro-F1*

(85.7%) presentan una gran proximidad, reflejando un comportamiento más homogéneo entre las distintas entidades evaluadas.

Mientras que *LayoutLMv3* alcanza un rendimiento superior en determinadas entidades específicas, *DONUT* presenta un comportamiento más homogéneo entre categorías.

El análisis comparativo también revela diferencias en el tipo de información que cada arquitectura procesa con mayor eficacia. *LayoutLMv3* alcanza sus mejores resultados en las entidades asociadas a las líneas de detalle (`lineas.descripcion`, `lineas.cantidad`, `lineas.precio_unitario` y `lineas.total_linea`), así como en los campos relacionados con los importes totales del documento, donde supera sistemáticamente el 97% de *F1-Score*. Estos resultados sugieren que la incorporación explícita de información textual y espacial proporciona una ventaja significativa cuando la extracción depende de la organización estructurada de la información dentro del documento.

Por su parte, *DONUT* obtiene resultados especialmente competitivos en numerosos campos de cabecera, incluyendo `proveedor.nombre`, `proveedor.direccion`, `cliente.nombre`, `cliente.direccion` y `cliente.ciudad`, donde supera ampliamente el rendimiento alcanzado por *LayoutLMv3*. Este comportamiento resulta coherente con el enfoque generativo de la arquitectura, que procesa el documento de forma global y no depende explícitamente de una etapa previa de segmentación y clasificación de entidades.

En conjunto, los resultados ponen de manifiesto dos estrategias de extracción complementarias: *LayoutLMv3* sobresale en entidades dependientes de la estructura espacial del documento, mientras que *DONUT* ofrece un rendimiento más uniforme entre los distintos tipos de información. Estas diferencias ayudan a explicar tanto la ventaja global de *LayoutLMv3* en el escenario de referencia como la mayor homogeneidad observada en las predicciones generadas por *DONUT*.

5.3.2. Impacto de la Degradación Visual

La capacidad de mantener el rendimiento ante documentos degradados constituye un aspecto fundamental para la aplicación práctica de sistemas de extracción de información en entornos logísticos-industriales. La figura 16 muestra la evolución del *F1-Score* de *LayoutLMv3* y *DONUT* bajo niveles crecientes de degradación visual generados artificialmente.

En términos cuantitativos, ambas arquitecturas experimentan una reducción significa-




Figura 16: Evolución consolidada del rendimiento global frente a la degradación visual.

tiva del rendimiento a medida que aumenta la severidad de las degradaciones. No obstante, *LayoutLMv3* muestra una mayor sensibilidad al ruido documental, registrando una disminución de 31.0 puntos porcentuales en Macro-F1 (del 84.6 % al 53.6 %). Por su parte, *DONUT* presenta una reducción más moderada, de 25.5 puntos porcentuales (del 81.5 % al 56.0 %), lo que le permite superar ligeramente a *LayoutLMv3* en el escenario de máxima degradación.

Con el objetivo de analizar con mayor detalle este comportamiento, la figura 17 presenta la evolución de las métricas de Precisión y *Recall* para ambas arquitecturas bajo los distintos niveles de ruido. El análisis de estas métricas permite identificar los mecanismos responsables de la pérdida progresiva de rendimiento observada.




Figura 17: Comparativa de la degradación paralela (*LayoutLMv3*) frente a la preservación de la Precisión (*DONUT*) bajo estrés visual.

Como puede observarse, ***LayoutLMv3* experimenta una degradación simultánea de la Precisión y el *Recall***, evidenciando un aumento tanto de los falsos positivos como de los falsos negativos conforme empeora la calidad visual de los documentos. En contraste, ***DONUT* mantiene valores de Precisión superiores al 90 % incluso bajo las condiciones más desfavorables, mientras que la principal degradación se concentra en la métrica de *Recall***. Este comportamiento indica que el modelo continúa generando predicciones mayoritariamente correctas cuando identifica una entidad, aunque aumenta progresivamente el número de omisiones.

Las tendencias observadas reflejan los compromisos inherentes a cada paradigma de procesamiento documental:

- ***LayoutLMv3*:** A pesar de alcanzar el mejor rendimiento en condiciones ideales, la arquitectura presenta una mayor degradación a medida que aumenta el nivel de ruido. Dado que el modelo depende de la información textual y espacial proporcionada por una etapa OCR previa, la pérdida de calidad documental puede afectar negativamente al proceso de extracción y clasificación de entidades. Como consecuencia, se observa una reducción simultánea de la Precisión y el *Recall*, reflejando un incremento

tanto de Falsos Positivos como de Falsos Negativos. Esta tendencia puede apreciarse con mayor detalle en las tablas de Verdaderos Positivos (VP), Falsos Positivos (FP) y Falsos Negativos (FN) incluidas en el Anexo A.1.

- **DONUT:** Aunque parte de un rendimiento inicial ligeramente inferior, la arquitectura presenta una degradación más gradual bajo condiciones adversas. Al operar mediante un enfoque *end-to-end* basado directamente en la imagen completa del documento, el modelo conserva valores de Precisión superiores al 90 % incluso en escenarios de degradación severa. Sin embargo, esta robustez viene acompañada de una reducción progresiva del *Recall*, indicando que la principal fuente de error corresponde a la omisión de entidades válidas más que a la generación de predicciones incorrectas. En términos de recuperación de información, este comportamiento se traduce en un crecimiento predominante de los Falsos Negativos, mientras que el número de Falsos Positivos permanece relativamente contenido. Esta evolución puede verificarse en las tablas detalladas de VP, FP y FN incluidas en el Anexo A.2.

5.3.3. Eficiencia Computacional

La evaluación de las arquitecturas analizadas debe complementarse con el estudio de los recursos computacionales requeridos para su entrenamiento e inferencia.

La tabla 13 presenta el perfil de consumo y rendimiento de ambos modelos durante la fase de inferencia bajo condiciones de degradación visual. Las filas corresponden a las arquitecturas evaluadas, mientras que las columnas recogen la latencia media por documento, la utilización de CPU y el consumo de memoria gráfica (VRAM) y memoria principal (RAM). En el caso de la latencia, el valor reportado corresponde a la media obtenida a partir de todos los niveles de ruido evaluados, proporcionando una estimación representativa del comportamiento operativo de cada arquitectura bajo distintas condiciones de captura documental.

Arquitectura	Latencia (s/doc)	CPU (%)	VRAM (GB)	RAM (GB)
<i>DONUT</i>	1.92	99.3	1.52	1.85
<i>LayoutLMv3</i>	3.56	14.3	2.53	3.16

Tabla 13: Requerimientos operativos promedio durante la fase de inferencia bajo condiciones de ruido visual.

De forma complementaria, la figura 18 resume los costes computacionales asociados al proceso de transferencia al dominio logístico. La subfigura (a) muestra el tiempo total requerido para la adaptación de cada arquitectura, mientras que la subfigura (b) recoge el consumo máximo de memoria gráfica (VRAM) alcanzado durante dicho proceso. Estos resultados permiten analizar el compromiso existente entre coste computacional y requerimientos de hardware.




Figura 18: Comparativa de costes computacionales durante la fase de adaptación al dominio (entrenamiento).

El análisis de las métricas computacionales permite identificar diferencias significativas entre ambas arquitecturas en términos de costes de adaptación al dominio, latencia de inferencia y utilización de recursos hardware:

- **Coste de adaptación al dominio:** Los resultados muestran un compromiso claro entre tiempo de entrenamiento y consumo de memoria. *DONUT* completó el proceso de adaptación al dominio en 3,9 horas, aproximadamente la mitad del tiempo requerido por *LayoutLMv3* (7,0 horas). Sin embargo, esta reducción temporal estuvo acompañada de un mayor consumo de memoria gráfica, alcanzando un pico de 13,9 GB de VRAM frente a los 8,1 GB registrados por *LayoutLMv3*.
- **Latencia de inferencia:** La comparación de los tiempos de ejecución revela diferencias notables entre ambas arquitecturas. Los valores reportados corresponden a la latencia media obtenida a partir de todos los niveles de ruido considerados en el estudio. *DONUT* registró una latencia media de 1,92 segundos por documento, mientras que *LayoutLMv3* alcanzó 3,56 segundos. Esta diferencia se explica principalmente por la necesidad de ejecutar nuevamente la etapa OCR cuando aumenta la degra-

dación visual, incrementando el tiempo total de procesamiento de la canalización basada en *LayoutLMv3*.

- **Utilización de recursos hardware:** Durante la inferencia, *DONUT* registró una utilización media de CPU del 99,3 %, asociada a la naturaleza secuencial de su proceso generativo. Por el contrario, *LayoutLMv3* presentó una utilización significativamente inferior (14,3 %), aunque requirió mayores cantidades de memoria RAM (3,16 GB frente a 1,85 GB) y VRAM (2,53 GB frente a 1,52 GB). Estos resultados evidencian estrategias de consumo de recursos claramente diferenciadas entre ambas arquitecturas.

5.4. Síntesis de Resultados

Los resultados obtenidos ponen de manifiesto las diferencias existentes entre los tres paradigmas de extracción de información evaluados: sistemas basados en OCR y reglas heurísticas, arquitecturas multimodales y modelos generativos de extremo a extremo. La solución *PaddleOCR + RegEx* representa una aproximación tradicional fundamentada en el reconocimiento óptico de caracteres y en conocimiento experto codificado mediante reglas. Los resultados muestran que este enfoque puede alcanzar niveles de rendimiento satisfactorios en escenarios controlados. Sin embargo, su capacidad de adaptación depende de la definición y mantenimiento de reglas específicas para cada estructura documental, lo que limita su escalabilidad ante cambios en el formato de los documentos o en los requisitos de extracción.

Entre las arquitecturas basadas en aprendizaje profundo, *LayoutLMv3* alcanza el mejor rendimiento global tras la adaptación al dominio logístico y destaca especialmente en la extracción de entidades asociadas a estructuras tabulares complejas. La integración explícita de información textual, visual y espacial permite explotar de forma eficaz la organización interna del documento y maximizar el rendimiento en condiciones de captura favorables. No obstante, este rendimiento se encuentra condicionado por la calidad de la información proporcionada por la etapa OCR previa, lo que incrementa la sensibilidad del sistema frente al deterioro visual de los documentos.

Por otro lado, la arquitectura *end-to-end* de *DONUT* elimina la dependencia de una etapa OCR independiente y procesa directamente la imagen completa del documento. Aunque su rendimiento en condiciones ideales resulta ligeramente inferior al de *LayoutLMv3*,

presenta un comportamiento más homogéneo entre entidades y una mayor robustez frente a escenarios de degradación visual severa. Asimismo, el análisis de las métricas de Precisión y *Recall* indica que, cuando aumenta la degradación visual, el modelo tiende a concentrar los errores en forma de falsos negativos, preservando niveles elevados de precisión en las entidades que consigue extraer.

En conjunto, los resultados muestran que la elección de la arquitectura más adecuada depende directamente de las características operativas del entorno de aplicación. En escenarios con documentos de buena calidad, tanto *LayoutLMv3* como *DONUT* ofrecen un rendimiento elevado, si bien destacan por fortalezas diferentes. Mientras que *LayoutLMv3* presenta una ventaja en la extracción de entidades fuertemente condicionadas por la estructura espacial del documento, *DONUT* exhibe un comportamiento más homogéneo entre categorías. Por otro lado, cuando los documentos presentan deterioro físico, degradaciones derivadas del proceso de digitalización o condiciones de captura variables, *DONUT* muestra una degradación más moderada del rendimiento y una mayor robustez frente al ruido visual. Finalmente, *PaddleOCR* + RegEx continúa siendo una alternativa válida cuando se dispone de documentos altamente estructurados y estables en el tiempo, aunque con una capacidad de adaptación más limitada que la ofrecida por las arquitecturas basadas en aprendizaje profundo.

6. Conclusiones y Trabajos Futuros

El presente capítulo consolida las conclusiones derivadas del estudio comparativo de las arquitecturas de IA Documental aplicadas al sector logístico industrial. Asimismo, se evalúa el grado de cumplimiento de los objetivos planteados al inicio de la investigación y se identifican posibles líneas de trabajo futuro orientadas a mejorar el rendimiento y la aplicabilidad de las soluciones analizadas.

6.1. Conclusiones del Estudio

La pregunta de investigación que ha guiado este trabajo ha sido:

¿Qué compromiso existe entre la precisión en la extracción semántica, la robustez frente a la degradación física documental, y el coste computacional en las principales arquitecturas abiertas de IA Documental aplicadas a documentos logísticos complejos bajo entornos de despliegue locales?

Los resultados obtenidos muestran que no existe una arquitectura capaz de optimizar simultáneamente las tres dimensiones analizadas. La precisión de extracción, la robustez frente a la degradación documental y el coste computacional mantienen una relación de compromiso que obliga a priorizar determinados criterios en función de los requisitos operativos del entorno de aplicación.

En este contexto, la evidencia experimental obtenida sugiere que la arquitectura *DONUT* constituye la alternativa más equilibrada para el escenario logístico industrial considerado en este trabajo.

Esta conclusión se fundamenta en los siguientes aspectos:

- **Eficiencia en la adaptación al dominio:** *DONUT* completó el proceso de adaptación al dominio logístico en 3.9 horas, aproximadamente la mitad del tiempo requerido por *LayoutLMv3* 7.0 horas.
- **Estabilidad temporal durante la inferencia:** Bajo condiciones de degradación visual, *DONUT* mantuvo una latencia media próxima a los 2 segundos por documento, mientras que *LayoutLMv3* alcanzó una media de 3.56 segundos.

- **Optimización de recursos hardware:** Durante la inferencia, *DONUT* requirió menos memoria que *LayoutLMv3* (1.52 GB frente a 2.53 GB de VRAM y 1.85 GB frente a 3.16 GB de RAM), aunque a costa de una mayor utilización de CPU (99.3% frente a 14.3%).
- **Homogeneidad del rendimiento entre entidades:** La proximidad entre los valores de *Micro-F1* (84.3%) y *Macro-F1* (85.7%) evidencia un comportamiento más uniforme entre categorías y una menor variabilidad de rendimiento entre entidades.
- **Fiabilidad predictiva frente a degradaciones documentales:** Aunque *LayoutLMv3* obtuvo un mejor resultado en condiciones ideales, *DONUT* mostró una degradación más moderada bajo ruido visual severo y mantuvo niveles elevados de precisión, limitando la aparición de falsos positivos.

6.2. Cumplimiento de Objetivos

A partir del desarrollo metodológico y de los resultados experimentales obtenidos, puede concluirse que los objetivos específicos definidos al inicio de la investigación han sido alcanzados satisfactoriamente:

1. **Preparar el corpus documental.** Se construyó un corpus sintético de 5.000 albaranes logísticos en español y se implementó un procedimiento de degradación documental capaz de reproducir distintos escenarios de captura y calidad visual.
2. **Despliegue de arquitecturas.** Se implementaron y configuraron las arquitecturas *PaddleOCR + RegEx*, *LayoutLMv3* y *DONUT* en un entorno experimental homogéneo de evaluación.
3. **Entrenamiento y adaptación al dominio.** Se aplicaron técnicas de transferencia de aprendizaje sobre el dominio logístico, permitiendo adaptar y evaluar las arquitecturas neuronales en la tarea de extracción de información de albaranes industriales.
4. **Evaluación comparativa.** Se analizaron las arquitecturas bajo distintos niveles de degradación documental mediante métricas de extracción, fidelidad textual y eficiencia computacional.

5. **Desarrollo de un marco de decisión.** Se estableció una metodología de evaluación basada en rendimiento, robustez y coste computacional, permitiendo identificar las fortalezas y limitaciones de cada paradigma documental.

6.3. Trabajos Futuros

Los resultados obtenidos durante esta investigación abren diversas líneas de trabajo orientadas a mejorar la eficacia, robustez y eficiencia computacional de los sistemas de IA documental aplicados al ámbito logístico:

- **Arquitecturas híbridas de selección dinámica:** Una línea de investigación especialmente prometedora consiste en el desarrollo de mecanismos de enrutamiento capaces de seleccionar automáticamente la arquitectura más adecuada en función de la calidad del documento de entrada. En este escenario, los documentos con una elevada calidad visual podrían procesarse mediante *LayoutLMv3* para aprovechar su capacidad de extracción en estructuras tabulares, mientras que los documentos degradados o capturados en condiciones adversas podrían derivarse a *DONUT* para beneficiarse de su mayor robustez frente al ruido documental.
- **Nuevas arquitecturas multimodales generativas:** Otra línea de interés consiste en evaluar modelos generativos más recientes basados en arquitecturas VLM (del inglés Vision-Language Models). La incorporación de técnicas de compresión, cuantización o adaptación eficiente de parámetros permitiría estudiar la viabilidad de estos modelos en entornos de despliegue local, manteniendo un equilibrio adecuado entre rendimiento de extracción y consumo de recursos.
- **Mecanismos de postprocesamiento semántico:** Los resultados obtenidos por *DONUT* muestran que una parte significativa de los errores se materializa en forma de entidades omitidas. En consecuencia, futuras investigaciones podrían incorporar módulos de validación y corrección semántica capaces de reconstruir información parcialmente extraída o inferir valores faltantes a partir del contexto documental, mejorando así la completitud de las respuestas generadas.

Referencias

- Appalaraju, S., Jasani, B. A., Kota, B. U., Xie, Y., y Manmatha, R. (2021). Docformer: End-to-end transformer for document understanding. *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, 973-983. Descargado de <https://api.semanticscholar.org/CorpusID:235592814>
- Baek, Y., Lee, B., Han, D., Yun, S., y Lee, H. (2019). Character region awareness for text detection. En *2019 IEEE/CVF conference on computer vision and pattern recognition (cvpr)* (p. 9357-9366). doi: 10.1109/CVPR.2019.00959
- Biten, A. F., Tito, R., Mafla, A., Gomez, L., Rusiñol, M., Jawahar, C., ... Karatzas, D. (2019). Scene text visual question answering. En *2019 IEEE/CVF international conference on computer vision (iccv)* (p. 4290-4300). doi: 10.1109/ICCV.2019.00439
- Breiman, L. (2001, 10). Random forests. *Machine Learning*, 45, 5-32. doi: 10.1023/A:1010950718922
- Buslaev, A., Iglovikov, V. I., Khvedchenya, E., Parinov, A., Druzhinin, M., y Kalinin, A. A. (2020). Albumentations: Fast and flexible image augmentations. *Information*, 11(2). Descargado de <https://www.mdpi.com/2078-2489/11/2/125> doi: 10.3390/info11020125
- Clark, A., y contributors. (2024). *Pillow: The friendly pil fork*. <https://github.com/python-pillow/Pillow>. GitHub.
- Cortes, C., y Vapnik, V. N. (1995). Support-vector networks. *Machine Learning*, 20, 273-297. Descargado de <https://api.semanticscholar.org/CorpusID:52874011>
- Du, Y., Li, C., Guo, R., Yin, X., Liu, W., Zhou, J., ... Wang, H. (2020). Pp-ocr: A practical ultra lightweight ocr system. *arXiv preprint arXiv:2009.09941*. doi: 10.48550/arXiv.2009.09941
- Elman, J. L. (1990). Finding structure in time. *Cogn. Sci.*, 14, 179-211. Descargado de <https://api.semanticscholar.org/CorpusID:2763403>
- Faraglia, R., y cols. (2024). *Faker: A python library for generating fake data*. <https://github.com/joke2k/faker>. GitHub.
- Frikha, M. A., y Mrad, M. (2025). Ai-enabled demand forecasting, technological capability, and supply chain performance: Empirical evidence from the global logistics sector. *International Journal of Advanced Computer Science and Applications*, 16(9). Descargado de <http://dx.doi.org/10.14569/IJACSA.2025.0160917> doi:

10.14569/IJACSA.2025.0160917

- Hochreiter, S., y Schmidhuber, J. (1997a). Long short-term memory. *Neural Computation*, 9, 1735-1780. Descargado de <https://api.semanticscholar.org/CorpusID:1915014>
- Hochreiter, S., y Schmidhuber, J. (1997b, 11). Long short-term memory. *Neural Computation*, 9, 1735-1780. doi: 10.1162/neco.1997.9.8.1735
- Huang, Y., Lv, T., Cui, L., Lu, Y., y Wei, F. (2022). Layoutlmv3: Pre-training for document ai with unified text and image masking. En *Proceedings of the 30th acm international conference on multimedia* (p. 4083–4091). New York, NY, USA: Association for Computing Machinery. Descargado de <https://doi.org/10.1145/3503161.3548112> doi: 10.1145/3503161.3548112
- IMARC Group. (2025). *Logistics market outlook*. IMARC Group. Descargado 2026-04-15, de <https://www.imarcgroup.com/logistics-market>
- JI, Z., LEE, N., FRIESKE, R., YU, T., SU, D., XU, Y., ... Fung, P. (2023, 31 de diciembre). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12). (Publisher Copyright: © 2023 Association for Computing Machinery.) doi: 10.1145/3571730
- Khallouli, W., Uddin, M. S., Sousa-Poza, A., Li, J., y Kovacic, S. (2025). Leveraging transformer-based ocr model with generative data augmentation for engineering document recognition. *Electronics*, 14(1). Descargado de <https://www.mdpi.com/2079-9292/14/1/5> doi: 10.3390/electronics14010005
- Kim, G., Hong, T., Yim, M., Nam, J., Park, J., Yim, J., ... Park, S. (2022). Ocr-free document understanding transformer. En S. Avidan, G. Brostow, M. Cissé, G. M. Farinella, y T. Hassner (Eds.), *Computer vision – eccv 2022* (pp. 498–517). Cham: Springer Nature Switzerland.
- Lafferty, J. D., McCallum, A. K., y Pereira, F. (2001). Conditional random fields: Probabilistic models for segmenting and labeling sequence data. En *International conference on machine learning*. Descargado de <https://api.semanticscholar.org/CorpusID:219683473>
- Li, C., Liu, W., Guo, R., Yin, X., Jiang, K., Du, Y., ... Ma, Y. (2022, 06). *Pp-ocrv3: More attempts for the improvement of ultra lightweight ocr system*. doi: 10.48550/arXiv.2206.03001
- Liao, M., Zou, Z., Wan, Z., Yao, C., y Bai, X. (2023). Real-time scene text detection

- with differentiable binarization and adaptive scale fusion. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(1), 919-931. doi: 10.1109/TPAMI.2022.3155612
- Liu, Y., Yang, B., Liu, Q., Li, Z., Ma, Z., Zhang, S., y Bai, X. (2024). Textmonkey: An ocr-free large multimodal model for understanding document. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 48, 6008-6019. Descargado de <https://api.semanticscholar.org/CorpusID:268264810>
- Mathew, M., Karatzas, D., y Jawahar, C. V. (2021). Docvqa: A dataset for vqa on document images. En *2021 IEEE Winter Conference on Applications of Computer Vision (WACV)* (p. 2199-2208). doi: 10.1109/WACV48630.2021.00225
- McKinsey & Company. (2021). *Succeeding in the ai supply-chain revolution*. McKinsey & Company. Descargado de <https://www.mckinsey.com/industries/metals-and-mining/our-insights/succeeding-in-the-ai-supply-chain-revolution>
- Memon, J., Sami, M., Khan, R. A., y Uddin, M. (2020). Handwritten optical character recognition (ocr): A comprehensive systematic literature review (slr). *IEEE Access*, 8, 142642-142668. doi: 10.1109/ACCESS.2020.3012542
- Ogrezeanu, I., Vizitiu, A., Ciuşdel, C., Puiu, A., Coman, S., Boldişor, C., ... Itu, L. (2022). Privacy-preserving and explainable ai in industrial applications. *Applied Sciences*, 12(13). Descargado de <https://www.mdpi.com/2076-3417/12/13/6395> doi: 10.3390/app12136395
- PaddleOCR. (2026). *General ocr pipeline usage tutorial*. Descargado 2026-04-20, de https://www.paddleocr.ai/latest/en/version3.x/pipeline_usage/OCR.html
- Park, J., Cho, J., Han, S., y Kim, K. (2025). Ocr-augmented gpt for accurate text extraction in industrial environments. *IEEE Access*, 13, 136226-136236. doi: 10.1109/ACCESS.2025.3594682
- Park, S., Shin, S., Lee, B., Lee, J., Surh, J., Seo, M., y Lee, H. (2019a). Cord: A consolidated receipt dataset for post-ocr parsing.
- Park, S., Shin, S., Lee, B., Lee, J., Surh, J., Seo, M., y Lee, H. (2019b). Cord: A consolidated receipt dataset for post-ocr parsing.. Descargado de <https://api.semanticscholar.org/CorpusID:207900784>
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... Chintala, S. (2019). Pytorch: An imperative style, high-performance deep learning library. *ArXiv, abs/1912.01703*. Descargado de <https://api.semanticscholar.org/CorpusID:>

202786778

- Shi, B., Bai, X., y Yao, C. (2017). An end-to-end trainable neural network for image-based sequence recognition and its application to scene text recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(11), 2298-2304. doi: 10.1109/TPAMI.2016.2646371
- Smith, R. (2007). An overview of the tesseract ocr engine. En *Ninth international conference on document analysis and recognition (icdar 2007)* (Vol. 2, p. 629-633). doi: 10.1109/ICDAR.2007.4376991
- Tesseract OCR Project. (2021). *Tesseract ocr documentation (version 5.x)*. (Disponible en: <https://tesseract-ocr.github.io/tessdoc/>)
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). Attention is all you need. En I. Guyon y cols. (Eds.), *Advances in neural information processing systems* (Vol. 30). Curran Associates, Inc. Descargado de https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf
- Verma, L. (2025). The transformative impact of artificial intelligence on business process management. *European Journal of Computer Science and Information Technology*, 13(48), 14-25. Descargado de <https://eajournals.org/wp-content/uploads/sites/21/2025/05/The-Transformative-Impact.pdf> doi: 10.37745/ejcsit.2013/vol13n481425
- Wang, W., Huang, Z., Luo, B., Chen, Q., Peng, Q., Pan, Y., ... Zhang, Y. (2022). mmlayout: Multi-grained multimodal transformer for document understanding. En *Proceedings of the 30th acm international conference on multimedia* (p. 4877-4886). New York, NY, USA: Association for Computing Machinery. Descargado de <https://doi.org/10.1145/3503161.3548406> doi: 10.1145/3503161.3548406
- Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., ... Rush, A. (2020, 01). Transformers: State-of-the-art natural language processing. En (p. 38-45). doi: 10.18653/v1/2020.emnlp-demos.6
- Xu, Y., Li, M., Cui, L., Huang, S., Wei, F., y Zhou, M. (2020). Layoutlm: Pre-training of text and layout for document image understanding. En *Proceedings of the 26th acm sigkdd international conference on knowledge discovery & data mining* (p. 1192-1200). New York, NY, USA: Association for Computing Machinery. Descargado de <https://doi.org/10.1145/3394486.3403172> doi: 10.1145/

3394486.3403172

Zhu, Z. (2023). *The function and significance of supply chain under the new situation of global economy*. <https://www.researchgate.net/publication/373896591>. (Accessed: 2026-06-08)

A. Resumen de verdaderos positivos, falsos positivos y falsos negativos

En este apéndice se recoge el desglose de resultados correspondiente a las arquitecturas *LayoutLMv3* y *DONUT* para cada una de las entidades evaluadas en el dominio logístico. En particular, se presentan los recuentos de verdaderos positivos (VP), falsos positivos (FP) y falsos negativos (FN) obtenidos durante la evaluación sobre el conjunto de prueba.

Los valores de verdaderos positivos reflejan las entidades correctamente identificadas y clasificadas, mientras que los falsos positivos representan predicciones incorrectas y los falsos negativos corresponden a entidades presentes en el documento que no fueron detectadas por el modelo.

La información aquí presentada complementa las métricas agregadas analizadas en el capítulo 5 y permite estudiar con mayor profundidad los patrones de error de cada modelo. Asimismo, facilita la interpretación de las diferencias observadas en términos de Precisión, *Recall* y *F1-Score*, al identificar las entidades que contribuyen en mayor medida a la aparición de falsos positivos y falsos negativos.

A.1. *LayoutLMv3*

La figura 19 muestra el desglose de verdaderos positivos (VP), falsos positivos (FP) y falsos negativos (FN) obtenido para cada una de las entidades evaluadas por la arquitectura *LayoutLMv3*. Cada fila corresponde a un campo específico del documento, mientras que las columnas representan el número de verdaderos positivos, falsos positivos y falsos negativos registrados durante la evaluación. Esta representación permite identificar de forma directa los campos que concentran un mayor número de errores de extracción y analizar la contribución de cada entidad a las métricas globales de Precisión, *Recall* y *F1-Score*.

Campo	lineas.descripcion	2694	26	26
	lineas.cantidad	2574	23	146
	lineas.precio_unitario	2650	13	70
	lineas.total_linea	2674	17	46
	numero_albaran	492	1	8
	fecha	496	1	4
	proveedor.cif	270	87	230
	proveedor.nombre	112	250	388
	cliente.direccion	359	141	141
	cliente.nombre	431	58	69
	proveedor.ciudad	498	1	2
	proveedor.direccion	320	176	180
	total	492	2	8
	iva_21	493	1	7
	subtotal	493	0	7
	cliente.ciudad	218	181	282
		VP	FP	FN

Figura 19: Distribución de verdaderos positivos (VP), falsos positivos (FP) y falsos negativos (FN) obtenida por la arquitectura *LayoutLMv3* para cada entidad evaluada.

A.2. DONUT

La figura 20 muestra el desglose de verdaderos positivos (VP), falsos positivos (FP) y falsos negativos (FN) obtenido para cada una de las entidades evaluadas por la arquitectura *DONUT*. Cada fila corresponde a un campo específico del documento, mientras que las columnas representan el número de verdaderos positivos, falsos positivos y falsos negativos registrados durante la evaluación. Esta representación permite identificar de forma directa los campos que concentran un mayor número de errores de extracción y analizar la contribución de cada entidad a las métricas globales de Precisión, *Recall* y *F1-Score*.

Campo	lineas.descripcion	1952	0	768
	lineas.cantidad	1943	22	777
	lineas.precio_unitario	1942	27	778
	lineas.total_linea	1927	39	793
	numero_albaran	372	27	128
	fecha	403	0	97
	proveedor.cif	396	7	104
	proveedor.nombre	396	5	104
	cliente.direccion	403	0	97
	cliente.nombre	397	7	103
	proveedor.ciudad	403	0	97
	proveedor.direccion	394	5	106
	total	383	3	117
	iva_21	337	5	163
	subtotal	354	6	146
	cliente.ciudad	404	0	96
		VP	FP	FN

Figura 20: Distribución de verdaderos positivos (VP), falsos positivos (FP) y falsos negativos (FN) obtenida por la arquitectura *DONUT* para cada entidad evaluada.

B. Repositorio del Proyecto

El código fuente desarrollado durante esta investigación, incluyendo los scripts de generación de datos, entrenamiento, evaluación y análisis de resultados, se encuentra disponible en el siguiente repositorio:

`https://github.com/danielhidalgo18/TFM-Document-AI-Logistics`

El repositorio incluye la documentación necesaria para reproducir los experimentos descritos en este trabajo.